Большое обучение EAGLE-3 с нуля: результаты

ours (слои 16/22/29 + `fc_norm`) против baseline (слои 2/16/29) для LLaMA-3.1-8B-Instruct

Команда EAGLE-3, большое обучение

15 октября 2026

Коротко

1. **Ours лучше baseline по реальной τ.** В SGLang в среднем по пяти бенчмаркам разница +0,037, 95 % интервал [+0,014; +0,060], $p \approx 0{,}001$. Выигрыш сосредоточен в диалогах: MT-bench +0,08, Alpaca +0,09, оба значимы. На коде, математике и пересказе разница в пределах шума. Код авторов даёт то же: +0,06 / +0,05 / −0,03 на MT-bench / HumanEval / GSM8K.
2. **На валидации ours впереди во всех 35 точках из 35** при равном числе диалогов. Разница растёт от +0,025 до +0,031 τ; в точке сравнения 3,865 против 3,828.
3. **Ours экономит данные:** чтобы выйти на ту же τ, baseline нужно на 8–15 % больше диалогов. На одних и тех же шагах и данных точность первого токена у ours выше на 0,24 п.п. — в 99 % строк лога.
4. **`fc_norm` ничего не стоит по скорости:** ускорение в SGLang 2,91× у ours и 2,90× у baseline. У официального драфта 3,06×: он сильнее на диалогах, наши — на коде и математике. Это разница данных обучения.
5. **Нашли и исправили баг SGLang 0.5.9.** Драфт со слоями не по умолчанию получал в CUDA-графах слои 2/16/29, и τ ours падала на 13 %. Исправление — в нашем пакете `sglang_eagle31`.
6. **Прогноз.** К одной эпохе ours дойдёт до τ-оценки ≈4,14, baseline — до ≈4,09; разрыв растёт. Отметку 4,0 ours пройдёт на 0,81–0,87 млн диалогов, baseline — на 0,92–0,98 млн.

1 Что сравнивали

Два драфта EAGLE-3 для LLaMA-3.1-8B-Instruct обучались с нуля одним и тем же кодом авторов (SafeAILab/EAGLE, `traineagle3`) на одной H200. Данные одинаковые и идут в одном порядке. Варианты отличаются только входом драфта (табл. 1). Первая попытка учить ours рецептом NeMo AutoModel сорвалась из-за роста логитов внимания; подробности — в отдельном отчёте «Почему ours больше не учится на NeMo».

Как мерили.

- *τ-оценка на валидации* считалась каждые 16 тыс. диалогов на одних и тех же 400 отложенных диалогах. Это ожидаемая длина одной цепочки драфта при измеренной точности по позициям: $\hat{\tau} = 1 + \sum_k \prod_{j \le k} \text{acc}_j$. Она ниже реальной τ на дереве, но хорошо упорядочивает варианты.
- *Реальная τ* — число принятых токенов за раунд проверки при настоящей генерации в SGLang 0.5.9. Дерево статьи (8 шагов, top-k 10, 60 токенов), T = 0, batch 1, по 80 вопросов на бенчмарк,

Таблица 1: Условия сравнения.

	baseline	**ours**
Слои цели, подаваемые в fc	2, 16, 29 (как в статье)	16, 22, 29
Нормировка входа fc	нет	`fc_norm` (как в EAGLE-3.1)
Общее		
Данные	PerfectBlend-Regenerated-Llama-3.1-8B-Instruct, 1 366 504 диалога в обучении; 2000 отложены, 400 из них — валидация	
Код и гиперпараметры	код авторов, DeepSpeed fp16, lr 5e-5 (WarmupDecayLR на одну эпоху), 8 диалогов на шаг, TTT 7 шагов	
Точка сравнения	шаг 68 325 = 546 600 диалогов = 0,4 эпохи; 33–37 ч H200 на вариант	

свободная GPU. Для контроля её же мерили кодом авторов на MT-bench, HumanEval и GSM8K.

- *Интервалы* — парный bootstrap по вопросам: оба драфта отвечают на одни и те же вопросы, 10 000 повторов.

2 Валидация: ours впереди с самого начала

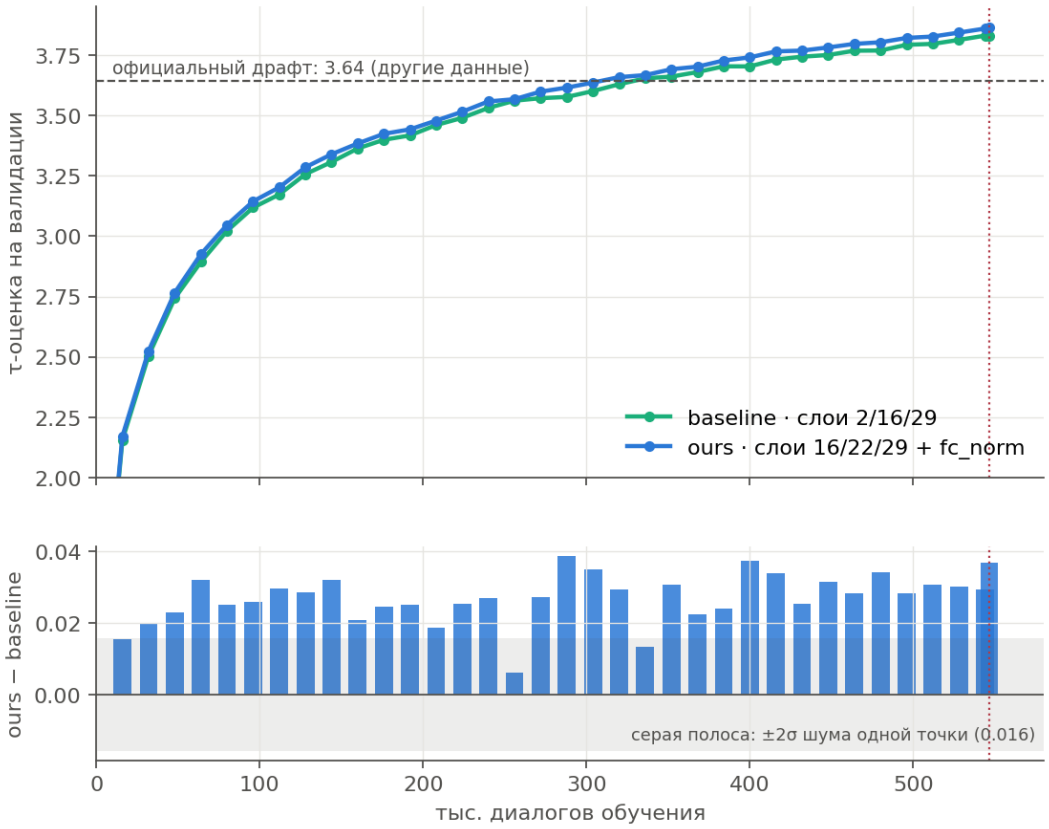


Рис. 1: τ-оценка на валидации в зависимости от числа увиденных диалогов. Снизу — разница ours − baseline в одних и тех же точках. Серая полоса — ±2σ шума одной точки; σ = 0,0078, оценён по разбросу точек вокруг гладкой кривой. Пунктир — точка сравнения.

Таблица 2: τ-оценка на валидации при равном числе диалогов (выборка точек; все 35 — в `tables.md`).

тыс. диалогов	ours	baseline	ours − baseline
16	2,171	2,156	+0,016
64	2,925	2,893	+0,032
128	3,285	3,256	+0,029
256	3,567	3,560	+0,006
384	3,727	3,703	+0,024
512	3,826	3,796	+0,030
544	3,859	3,830	+0,029
546,6	**3,865**	3,828	**+0,037**

Знак разницы не меняется ни разу: 35 точек из 35. Средняя разница по участкам: +0,025 (до 128 тыс.), +0,026 (128–320 тыс.), +0,029 (320–546,6 тыс.). Преимущество не тает по мере обучения, а слегка растёт. В последних пяти точках оно в среднем +0,031, это около 4σ шума одной точки.

3 Ours тратит меньше данных

Для каждой точки ours мы нашли, сколько диалогов нужно baseline, чтобы выйти на ту же τ-оценку. Для этого использована гладкая кривая baseline: степенной закон, подогнанный по точкам от 64 тыс. (рис. 2). Разрыв растёт со временем: 3–10 % в первой половине обучения, 8–15 % в последних восьми точках. Свои 3,865 ours набрал за 546,6 тыс. диалогов; baseline до них за это время не дошёл.



Рис. 2: Сколько процентов диалогов baseline нужно сверх ours, чтобы выйти на ту же τ-оценку.

Парное сравнение на обучении. Оба запуска видят одни и те же диалоги на одних и тех же шагах, поэтому строки лога можно сравнивать попарно. На последних 300 общих строках (шаги 53 350–68 300) точность первого токена у ours выше на **+0,24 п.п.**, лосс первой позиции ниже на 0,003. Ours впереди в 99 % строк (рис. 3).

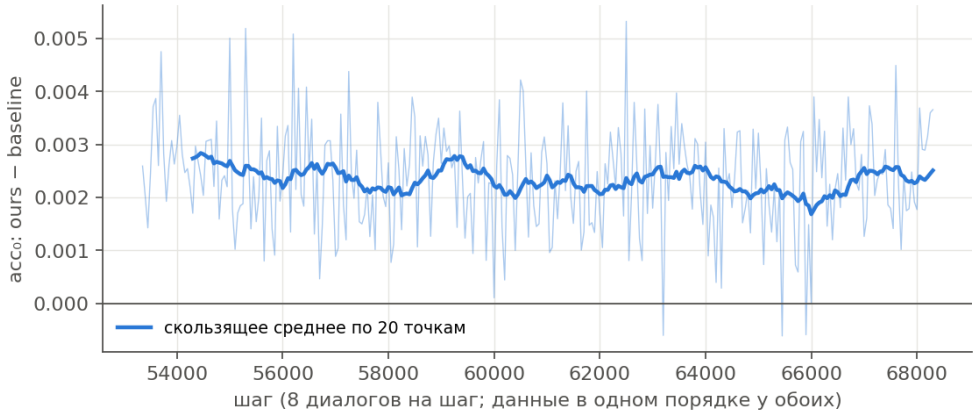


Рис. 3: Разница точности первого токена ours − baseline на обучении, на тех же шагах и тех же данных.

По позициям цепочки ours выигрывает везде: от +0,21 до +0,57 п.п., больше всего на последней, 7-й позиции (рис. 4). На своей валидации оба наших драфта по каждой позиции точнее официального драфта авторов. Но это домен наших данных; см. раздел 4.

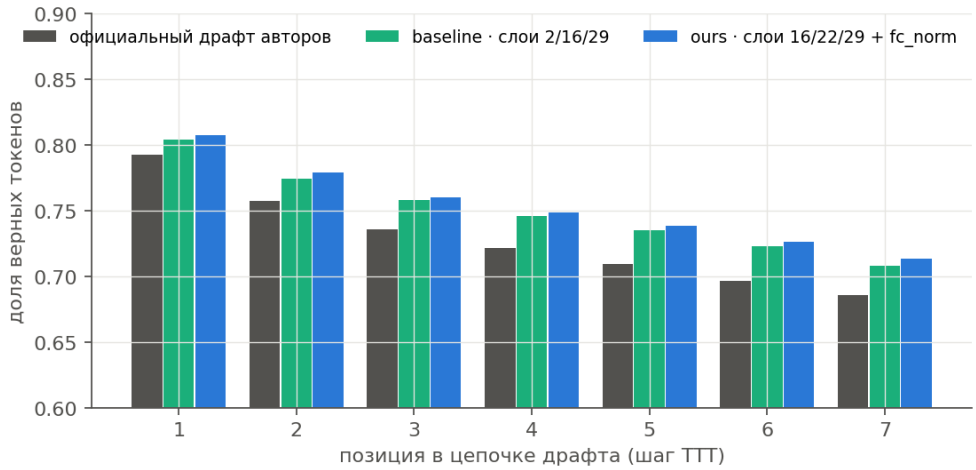


Рис. 4: Точность драфта по позициям цепочки на валидации в точке сравнения и у официального драфта на тех же 400 диалогах.

4 Реальная τ и ускорение

Таблица 3: Реальная τ: SGLang 0.5.9, дерево 8/10/60, T = 0, 80 вопросов. В скобках — код авторов на том же дереве. Последняя строка — разница ours − baseline в SGLang и 95 % интервал.

драфт	MT-bench	HumanEval	GSM8K	Alpaca	CNN/DM	среднее
официальный	**6,11** (6,18)	6,69 (6,74)	6,18 (6,26)	**6,63**	**5,34**	**6,19**
baseline	4,95 (4,98)	7,54 (7,56)	**7,41** (7,43)	4,71	3,96	5,71
ours	5,03 (5,04)	**7,56** (7,61)	7,39 (7,41)	4,80	3,97	5,75
ours − baseline	**+0,080**	+0,024	−0,015	**+0,087**	+0,011	**+0,037**
95 % интервал	[+0,05; +0,11]	[−0,02; +0,07]	[−0,09; +0,06]	[+0,04; +0,14]	[−0,03; +0,05]	[+0,014; +0,060]

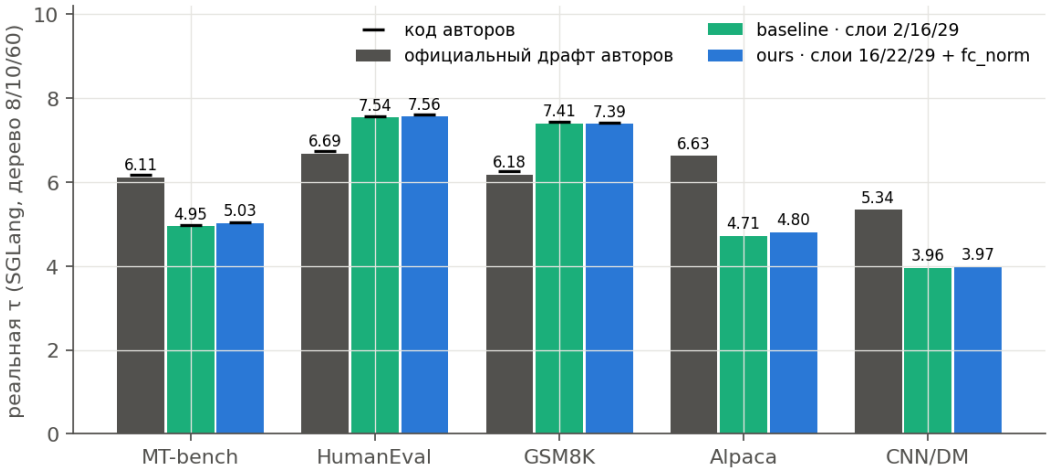


Рис. 5: Реальная τ по бенчмаркам. Столбцы — SGLang, чёрные штрихи — код авторов.

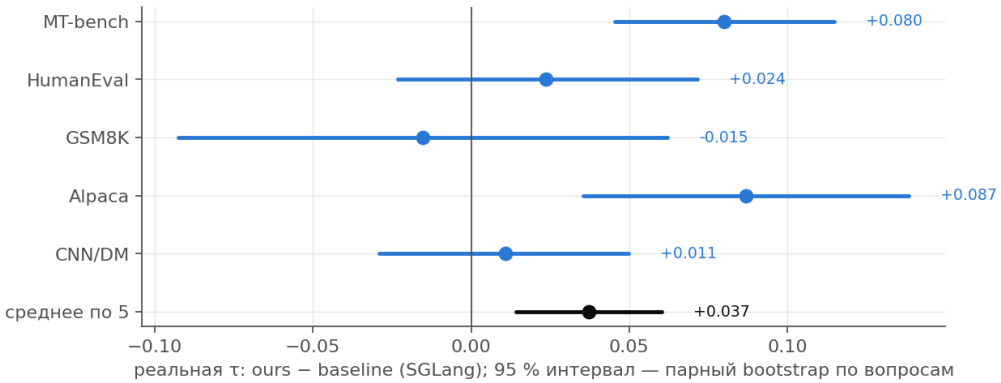


Рис. 6: Реальная τ: ours – baseline в SGLang, точка и 95 % интервал (парный bootstrap по вопросам).

- **Ours лучше в среднем, и это значимо:** +0,037 τ, +0,65 %; интервал не задевает ноль, $p \approx 0{,}001$. Валидация предсказала примерно столько же: +0,037 τ-оценки, +1,0 %.
- **Выигрыш — в диалогах:** MT-bench +0,08 и Alpaca +0,09, оба значимы. На HumanEval, GSM8K и CNN/DM разница в пределах шума. Там τ либо уже высокая (код, математика), либо драфт упирается в данные (пересказ).
- **Стенды согласованы.** SGLang и код авторов совпадают с точностью до 0,08 для всех трёх драфтов. Для ours — только после исправления бага SGLang (раздел 5).
- **С официальным драфтом сравнение нечестное по данным.** Его учили на ShareGPT и UltraChat и намного дольше. Мы учили на PerfectBlend, где много кода и математики. Поэтому наши драфты уже за 0,4 эпохи обгоняют официальный на HumanEval и GSM8K (+0,9 и +1,2), но отстают на диалогах и пересказе (−1,1…−1,9).

Ускорение повторяет τ. `fc_norm` — три RMSNorm на вход fc — по скорости незаметна: при одинаковой τ ours и baseline дают одинаковые токены в секунду.

5 Баг SGLang 0.5.9: слои цели в CUDA-графах

Первый замер ours в SGLang (14.10) дал τ на 13 % ниже, чем код авторов на том же драфте: 4,36 против 5,04 на MT-bench. Для официального драфта и baseline стенды совпадали. Причина — порядок инициализации в SGLang 0.5.9:

Таблица 4: Ускорение в SGLang: скорость с драфтом, делённая на обычную генерацию на той же GPU (batch 1, свободная H200). В скобках — токенов в секунду.

драфт	MT-bench	HumanEval	GSM8K	Alpaca	CNN/DM	среднее
официальный	**2,95×** (532)	3,36× (615)	3,15× (583)	**3,38×** (621)	**2,46×** (426)	**3,06×**
baseline	2,57× (463)	3,76× (687)	**3,77×** (697)	2,57× (473)	1,85× (321)	2,90×
ours	2,59× (466)	3,76× (687)	3,75× (694)	2,61× (479)	1,86× (322)	2,91×
обычная генерация	180	183	185	184	174	

1. Слои цели, которые нужно захватывать, SGLang читает из конфига драфта (`eagle_aux_hidden_state_layer_ids`).
2. Но `CudaGraphRunner` перед записью графов вызывает `set_eagle3_layers_to_capture()` без аргументов. В графы decode и проверки дерева записываются слои по умолчанию: 2, N/2, N−3.
3. Слои из конфига выставляются уже после этого и действуют только в prefill, который идёт без графов.

Драфты со слоями по умолчанию (официальный, baseline) ошибки не замечают. Ours же в каждом раунде проверки получал признаки слоёв baseline вместо своих.

Исправление — в нашем внешнем пакете `sglang_eagle31`, который SGLang и так загружает ради `fc_norm`. Подменены две функции: вызов без аргументов теперь берёт слои из конфига драфта, которые модель уже прочитала до записи графов. В логе сервера появляется строка `target layers to capture (output ids) [15, 21, 28], also in CUDA graphs`.

Таблица 5: Реальная τ ours в SGLang до и после исправления; для сравнения — код авторов.

ours	MT-bench	HumanEval	GSM8K	Alpaca	CNN/DM	среднее
SGLang без исправления	4,36	6,64	6,30	4,18	3,46	4,99
SGLang с исправлением	5,03	7,56	7,39	4,80	3,97	5,75
код авторов	5,04	7,61	7,41	—	—	—

Вывод для всех, кто переносит драфты со своими слоями в SGLang: сверять τ с кодом авторов на каждом новом драфте. Баг молчаливый: сервер работает, ускорение есть, но заметно меньше, чем должно быть.

6 Прогноз: сколько ещё учить

Кривые τ-оценки хорошо описываются насыщающимся степенным законом $\tau(n) = a - b\,n^{-c}$, где n — тысячи диалогов, $c \approx 0{,}22$. Мы подогнали его по точкам начиная с 32, 64 и 128 тыс. и экстраполировали (рис. 7). Разброс трёх подгонок служит грубой мерой неопределённости.

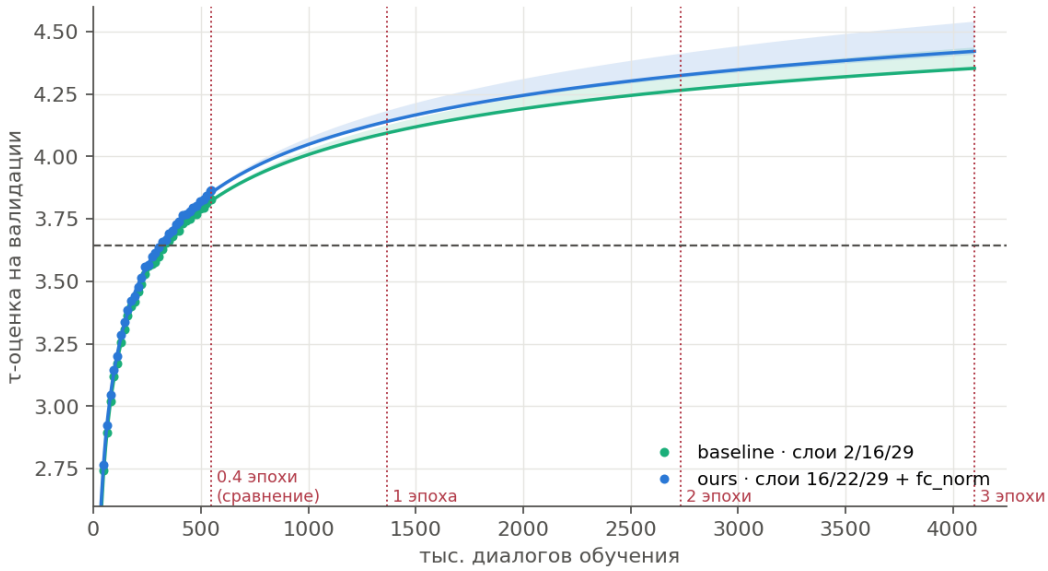


Рис. 7: Экстраполяция τ-оценки на 1–3 эпохи. Линия — подгонка с 64 тыс., полоса — разброс трёх подгонок, пунктир — официальный драфт на нашей валидации.

Таблица 6: Прогноз τ-оценки на валидации и число диалогов до заданного уровня.

	0,4 эпохи (546,6 тыс.)	1 эпоха (1,37 млн)	2 эпохи (2,73 млн)	3 эпохи (4,10 млн)
baseline	3,83 (замер)	4,09 (4,09–4,12)	4,26 (4,26–4,33)	4,35 (4,35–4,44)
ours	3,87 (замер)	**4,14** (4,13–4,18)	**4,32** (4,31–4,41)	**4,42** (4,41–4,54)
	до $\hat{\tau} = 3{,}9$	до 4,0	до 4,1	до 4,2
baseline, млн диалогов	0,68–0,70	0,92–0,98	1,27–1,40	1,76–2,08
ours, млн диалогов	0,62–0,63	**0,81–0,87**	**1,08–1,21**	**1,44–1,74**

- **Отдача от данных падает медленно.** Измеренный прирост за удвоение был 0,36 → 0,30 → 0,24 у baseline и 0,36 → 0,28 → 0,26 у ours. По прогнозу дальше будет 0,22 → 0,19 → 0,17 у ours и 0,21 → 0,18 → 0,15 у baseline. Драфт далёк от насыщения, а разрыв по прогнозу растёт: +0,05 к одной эпохе, +0,07 к трём. Асимптота по 0,4 эпохи определяется плохо, поэтому прогноз дан только до трёх эпох.
- **Прогноз скорее занижен.** Расписание lr рассчитано на одну эпоху и спадает к нулю к её концу; в точке сравнения lr ещё 3,2e-5. Полная эпоха с отжигом lr обычно добавляет сверх степенного закона, подогнанного на участке с высоким lr.
- **Цена.** Один вариант на свободной H200 учится со скоростью 9,7 диалога/с. До конца первой эпохи осталось 0,82 млн диалогов — ≈23,5 ч, около трёх 8-часовых сессий на вариант. Три эпохи с нуля — около 118 ч на вариант.
- **На диалогах главный рычаг — состав данных,** а не только их объём. Официальный драфт с меньшей τ-оценкой на нашей валидации выигрывает на MT-bench и Alpaca. Чтобы обогнать его на диалогах, стоит добавить в обучение ShareGPT и UltraChat или перегенерировать их ответы целью.

7 Как шла финальная стадия

Хронология

14.10 до 15:27 — оценены официальный драфт и baseline (SGLang + код авторов), baseline завершён на шаге 68 325.
14.10 17:03 — узел перестал отвечать по сети. Работа на нём при этом продолжалась.
14.10 17:42 — ours дошёл до шага 68 325 (τ-оценка 3,865). Вторая часть оценки прошла сама: ours в SGLang и кодом авторов, обычная генерация, чистые замеры скорости официального драфта и baseline (до 18:22).
15.10 12:20 — доступ восстановлен. Найдено расхождение SGLang и кода авторов для ours, найдена причина — баг захвата слоёв (раздел 5).
15.10 12:23–12:29 — ours перемерен в SGLang с исправлением.

Данные и воспроизводимость

Всё лежит в репозитории проекта, в папке `big-training/`. Числа и графики этого отчёта пересчитываются командой `python code/make_results_figures.py`. Исходные данные — в `results/llama31-8b/`:

- `<вариант>/val.jsonl` — вся история валидации;
- `<вариант>/metrics.jsonl` — последние 300 строк лога;
- `final_eval/` — реальная τ по вопросам для каждого драфта, обычной генерации и замера ours без исправления, а также итоги кода авторов (собирает `code/collect_final_eval.py`);
- `reference.json` — официальный драфт на нашей валидации.

Итоги — в `results.json` и `tables.md`. Код обучения, мониторинга и оценки — в `code/`, как запускать — в `code/README.md`.