Большое обучение EAGLE-3 с нуля: результаты

ours (слои 16/22/29 + `fc_norm`) против baseline (слои 2/16/29) для LLaMA-3.1-8B-Instruct: что успели измерить до потери узла H200

Команда EAGLE-3, большое обучение

14 октября 2026

Коротко

1. **Ours лучше baseline при равном числе диалогов — во всех 32 точках валидации из 32.** Разница растёт от +0,025 до +0,028 τ, в последних пяти точках +0,030. Это около 4σ шума одной точки валидации.
2. **Ours экономит данные:** baseline нужно в среднем на 6–9 % больше диалогов, чтобы выйти на ту же τ.
3. **То же видно на обучении.** На одних и тех же шагах и данных точность первого токена у ours выше на 0,23 п.п. Так в 247 строках лога из 249.
4. **Реальная τ в SGLang** измерена для официального драфта и baseline: в среднем 6,19 и 5,71. Код авторов даёт те же цифры (расхождение ≤0,08). На коде и математике baseline сильнее официального драфта, на диалогах и пересказе слабее: так сказывается разница в данных обучения.
5. **Реальную τ для ours измерить не успели.** Узел пропал в 17:03, за 36 минут до точки сравнения. Пересчёт через валидацию даёт около +0,8 % к baseline, то есть ≈5,76 в среднем. Это прогноз, а не замер.
6. **Прогноз.** Каждое удвоение данных добавляет 0,21 → 0,18 → 0,15 τ на валидации. К одной эпохе (1,37 млн диалогов) ours дойдёт до ≈4,13, baseline до ≈4,09. Отметку 4,0 ours пройдёт на 0,83–0,88 млн диалогов, baseline — на 0,92–0,98 млн. Преимущество ours по прогнозу сохраняется.

1 Что сравнивали

Два драфта EAGLE-3 для LLaMA-3.1-8B-Instruct обучались с нуля одним и тем же кодом авторов (SafeAILab/EAGLE, `traineagle3`) на одной H200. Данные одинаковые и идут в одном порядке. Варианты отличаются только входом драфта (табл. 1). Первая попытка учить ours рецептом NeMo AutoModel сорвалась из-за роста логитов внимания; подробности — в отдельном отчёте «Почему ours больше не учится на NeMo».

Как мерили. Во время обучения каждые 16 тыс. диалогов считалась *τ-оценка* на тех же 400 отложенных диалогах. Это ожидаемая длина одной цепочки драфта при измеренной точности по позициям: $\hat{\tau} = 1 + \sum_k \prod_{j \le k} \mathrm{acc}_j$. Она ниже реальной τ на дереве, но хорошо их упорядочивает. *Реальная* τ — это число принятых токенов за раунд проверки в SGLang 0.5.9: дерево статьи (8 шагов, top-k 10, 60 токенов), T = 0, по 80 вопросов на бенчмарк. Для контроля её же мерили кодом авторов.

Таблица 1: Условия сравнения.

	baseline	**ours**
Слои цели, подаваемые в fc	2, 16, 29 (как в статье)	16, 22, 29
Нормировка входа fc	нет	`fc_norm` (как в EAGLE-3.1)
Общее		
Данные	PerfectBlend-Regenerated-Llama-3.1-8B-Instruct, 1 366 504 диалога в обучении; 2000 отложены, 400 из них — валидация	
Код и гиперпараметры	код авторов, DeepSpeed fp16, lr 5e-5 (WarmupDecayLR на одну эпоху), 8 диалогов на шаг, TTT 7 шагов	
Точка сравнения	шаг 68 325 = 546 600 диалогов = 0,4 эпохи	

2 Валидация: ours впереди с самого начала

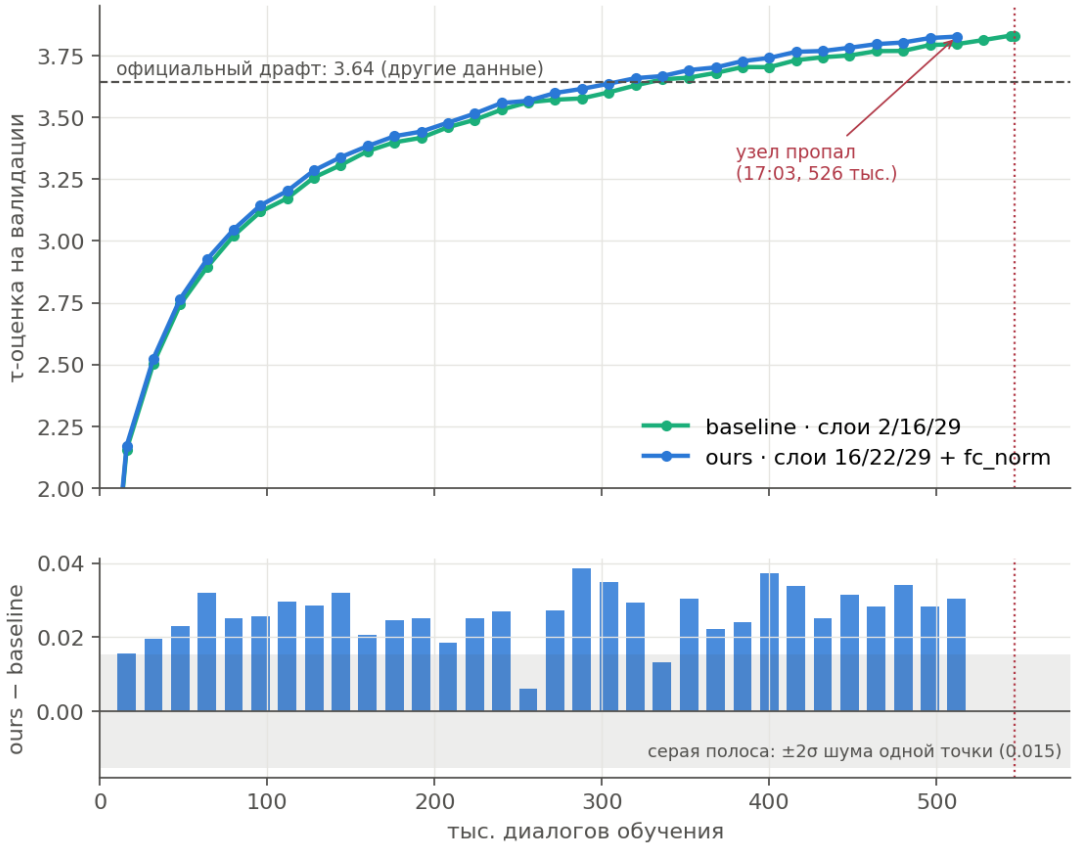


Рис. 1: т-оценка на валидации в зависимости от числа увиденных диалогов. Снизу — разница ours − baseline в одинаковых точках. Серая полоса — ±2σ шума одной точки; σ = 0,0076, оценён по разбросу точек вокруг гладкой кривой. Красная пунктирная линия — точка сравнения. Ours остановился на 526 тыс. диалогов: последняя валидация на 512 тыс.

- **Знак разницы не меняется ни разу:** 32 точки из 32. Средняя разница по участкам: +0,025 (до 128 тыс.), +0,026 (128–320 тыс.), +0,028 (320–512 тыс.). Преимущество не тает по мере обучения.

Таблица 2: τ-оценка на валидации при равном числе диалогов (выборка точек; все 32 — в `tables.md`).

тыс. диалогов	ours	baseline	ours − baseline
16	2,172	2,156	+0,016
64	2,925	2,893	+0,032
128	3,285	3,256	+0,029
256	3,567	3,560	+0,006
384	3,727	3,703	+0,024
448	3,781	3,750	+0,031
480	3,802	3,768	+0,034
512	**3,826**	3,796	**+0,030**
546,6	—	3,828	—

- **Ours на 512 тыс. уже на уровне финального baseline:** 3,826 против 3,828 на 546,6 тыс. Если разница последних точек сохранится, в точке сравнения ours был бы на ≈3,85–3,86.

3 Ours тратит меньше данных

Для каждой точки ours мы нашли, сколько диалогов нужно baseline, чтобы выйти на ту же τ-оценку. Для этого использована гладкая кривая baseline: степенной закон, подогнанный по точкам от 64 тыс. (рис. 2).



Рис. 2: Сколько процентов диалогов baseline нужно сверх ours, чтобы выйти на ту же τ-оценку.

Разница растёт со временем: 3–10 % в первой половине, 8–11 % в последних восьми точках, в среднем по последним восьми 8,9 %. Прямая интерполяция по точкам baseline даёт тот же порядок. Например, свои 3,826 ours набрал за 512 тыс. диалогов, а baseline — за ≈541 тыс. (+5,6 %).

Парное сравнение на обучении. Оба запуска видят одни и те же диалоги на одних и тех же шагах. Поэтому строки лога можно сравнивать попарно. На последних 249 общих строках (шаги 53 350–65 750) точность первого токена у ours выше на **+0,23 п.п.**, лосс первой позиции ниже на 0,003. Ours впереди в 99 % строк (рис. 3).

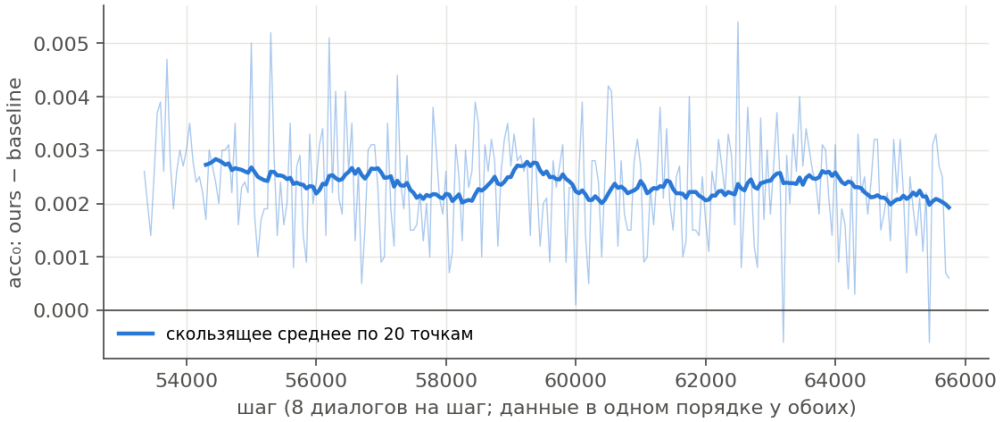


Рис. 3: Разница точности первого токена ours – baseline на обучении, на тех же шагах и тех же данных.

По позициям цепочки ours выигрывает везде: от +0,13 до +0,53 п.п. Больше всего на 2-й и 3-й позициях (рис. 4). На своей валидации оба наших драфта по каждой позиции точнее официального драфта авторов. Но это домен наших данных; см. раздел 4.

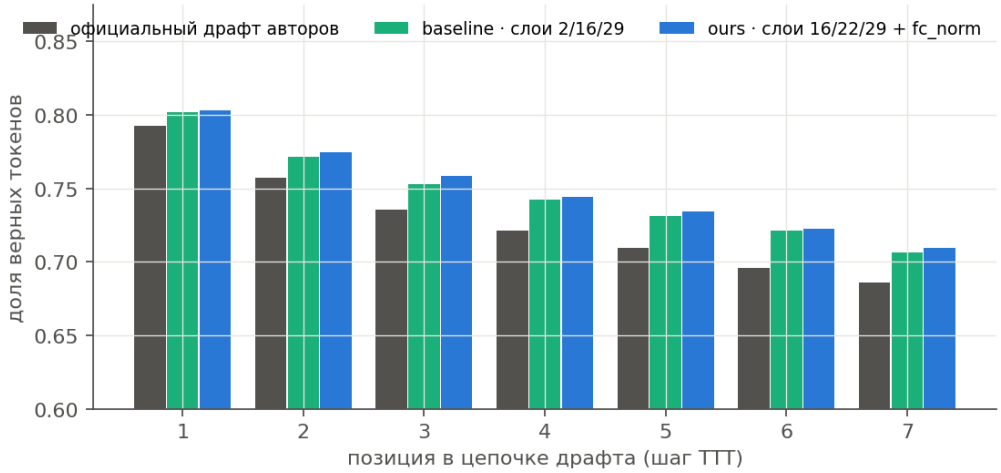


Рис. 4: Точность драфта по позициям цепочки на валидации (512 тыс. диалогов) и у официального драфта на тех же 400 диалогах.

4 Реальная τ в SGLang

Первая часть финальной оценки прошла 14.10 до 15:27, вторая ждала, пока ours дойдёт до точки сравнения. Результаты — в табл. 3 и на рис. 5. Скорость (ток/с) не приводим: в это время GPU делилась с обучением ours, и замеры несравнимы.

Таблица 3: Реальная τ: SGLang, дерево 8/10/60, T = 0, 80 вопросов. В скобках — код авторов на том же дереве.

драфт	MT-bench	HumanEval	GSM8K	Alpaca	CNN/DM	среднее
официальный	**6,11** (6,18)	6,69 (6,74)	6,18 (6,26)	**6,63**	**5,34**	**6,19**
baseline, 546,6 тыс.	4,95 (4,98)	**7,54** (7,56)	**7,41** (7,43)	4,71	3,96	5,71
ours, прогноз	*≈4,99*	*≈7,60*	*≈7,47*	*≈4,75*	*≈3,99*	*≈5,76*

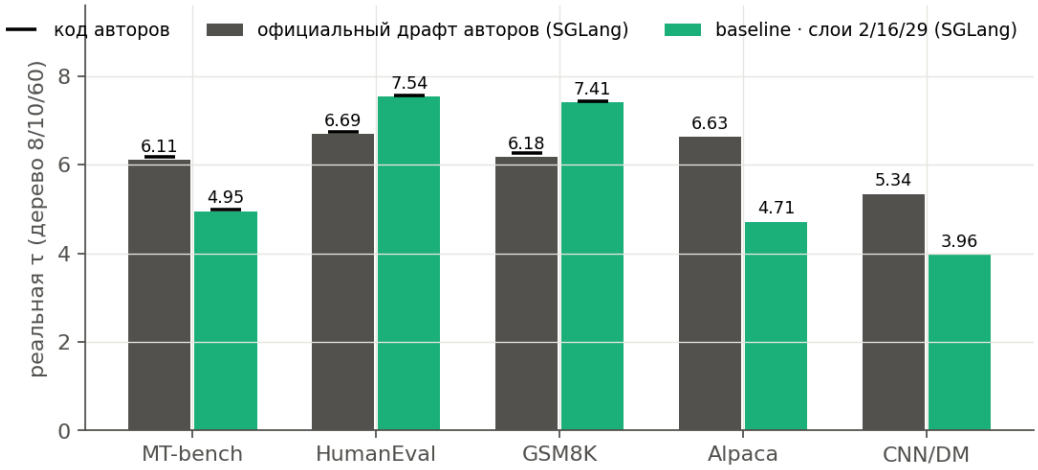


Рис. 5: Реальная τ по бенчмаркам. Столбцы — SGLang, чёрные штрихи — код авторов.

- **Стенд надёжный.** SGLang и код авторов совпадают с точностью до 0,08 и для официального драфта, и для нашего baseline. Значит, наш экспорт в SGLang корректен. Для `fc_norm` в SGLang подготовлен внешний пакет модели `sglang_eagle31`; на ours он проверится вместе с замером.
- **С официальным драфтом сравнение нечестное по данным.** Его учили на ShareGPT и UltraChat и намного дольше. Мы учили на PerfectBlend, где много кода и математики. Поэтому baseline уже за 0,4 эпохи обгоняет официальный драфт на HumanEval (+0,85) и GSM8K (+1,23), но отстаёт на диалогах (MT-bench −1,16, Alpaca −1,92) и пересказе (CNN/DM −1,38).
- **Прогноз для ours** получен умножением τ baseline на отношение τ-оценок на валидации в точке сравнения (3,859 / 3,828 = 1,008). Он предполагает, что реальная τ растёт пропорционально валидационной. Нужен замер; см. раздел 6.

5 Прогноз: сколько ещё учить

Кривые τ-оценки хорошо описываются насыщающимся степенным законом $\tau(n) = a - b\,n^{-c}$; n — тысячи диалогов, $c \approx 0{,}22$. Мы подогнали его по точкам начиная с 32, 64 и 128 тыс. и экстраполировали (рис. 6). Разброс трёх подгонок — грубая мера неопределённости.

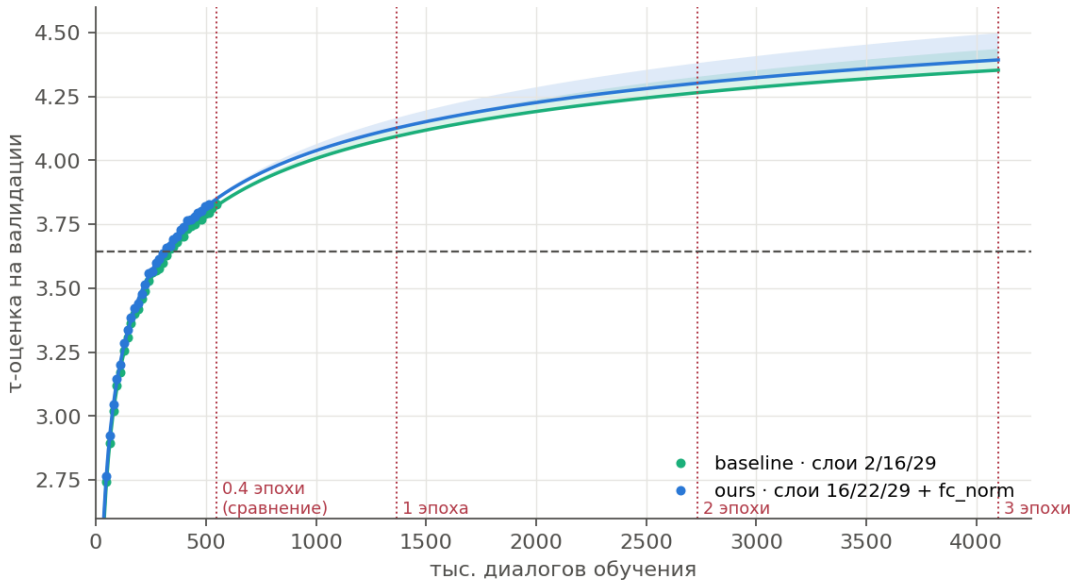


Рис. 6: Экстраполяция τ-оценки на 1–3 эпохи. Линия — подгонка с 64 тыс., полоса — разброс трёх подгонок, пунктир — официальный драфт на нашей валидации.

Таблица 4: Прогноз τ-оценки на валидации и число диалогов до заданного уровня.

	0,4 эпохи (546,6 тыс.)	1 эпоха (1,37 млн)	2 эпохи (2,73 млн)	3 эпохи (4,10 млн)
baseline	3,83 (замер)	4,09 (4,09–4,12)	4,26 (4,26–4,33)	4,35 (4,35–4,44)
ours	≈3,85–3,86	**4,13** (4,12–4,16)	**4,30** (4,30–4,38)	**4,39** (4,39–4,50)
	до $\hat{\tau} = 3{,}9$	до 4,0	до 4,1	до 4,2
baseline, млн диалогов	0,68–0,70	0,92–0,98	1,27–1,40	1,76–2,08
ours, млн диалогов	0,62–0,64	**0,83–0,88**	**1,12–1,25**	**1,52–1,82**

- **Отдача от данных падает медленно.** Измеренный прирост за удвоение был 0,36 → 0,30 → 0,24 (baseline) и 0,36 → 0,28 → 0,26 (ours). По прогнозу дальше будет 0,21 → 0,18 → 0,15. За 0,4 эпохи драфт далёк от насыщения. Асимптота кривой по 0,4 эпохи определяется плохо: подгонки дают от 5,2 до 6,9. Поэтому прогноз дан только до 3 эпох.
- **Прогноз скорее занижен.** Расписание lr рассчитано на одну эпоху и спадает к нулю к её концу; в точке сравнения lr ещё 3,2e-5. Полная эпоха с отжигом lr обычно добавляет сверх степенного закона, подогнанного на участке с высоким lr.
- **Цена.** Один вариант на свободной H200 учится со скоростью 9,7 диалога/с. До конца первой эпохи осталось 0,82 млн диалогов: это ≈23,5 ч, около трёх 8-часовых сессий на вариант. Два варианта вместе идут по 4,4 диалога/с, это ≈52 ч. Три эпохи с нуля — около 118 ч на вариант.
- **По реальной τ** главный рычаг для диалогов — состав данных, а не только их объём. Официальный драфт с меньшей τ-оценкой на нашей валидации выигрывает на MT-bench и Alpaca. Чтобы обогнать его на диалогах, стоит добавить в обучение ShareGPT и UltraChat или перегенерировать ответы целью.

6 Что случилось с узлом и чего не хватает

Хронология 14 октября

до 15:27 — оценены официальный драфт и baseline (SGLang + код авторов), baseline завершён на шаге 68 325.
15:30 — на сервере на автомате поставлена вторая часть оценки: ours, обычный сервер для знаменателя ускорения, чистые замеры скорости.
17:02:57 — последнее обновление статуса ours: шаг 65 750 (526 тыс. диалогов), 9,54 диалога/с, сбоев нет.
≈17:03 — узел пропадает из сети. Следующая строка лога (каждые ≈42 с) не пришла, узел не отвечает по сети.
19:13 — ClearML помечает задачи как остановленные (по-видимому, по таймауту 2 ч без связи).
19:51 — плановый конец сессии. На 20:30 узел всё ещё недоступен.

Где именно оборвалось — на узле или только в сети — снаружи не видно. Если сессия упала, ours продолжит с последнего сохранения кодом авторов (resume штатный). Когда доступ вернётся, остаётся около двух часов работы:

1. Доучить ours до шага 68 325 — ≤40 мин на свободной GPU (плюс повтор с последнего сохранения).
2. `final_eval_part2.sh`: реальная τ ours в SGLang и кодом авторов, обычный сервер для ускорения, чистые скорости официального драфта и baseline — ≈1 ч.

Данные и воспроизводимость

Всё лежит в репозитории проекта, в папке `big-training/`. Числа и графики этого отчёта пересчитываются командой `python code/make_results_figures.py`. Исходные данные — в `results/llama31-8b/`: `<вариант>/val.jsonl` (вся история валидации), `<вариант>/metrics.jsonl` (последние 300 строк лога), `status.json`, `reference.json` (официальный драфт на нашей валидации), `final_eval_part1.json` (реальная τ). Итоги — в `results.json` и `tables.md`. Код обучения, мониторинга и оценки — в `code/`; как запускать, написано в `code/README.md`.