Устаревание драфта EAGLE после дообучения target

Карта, предсказание по весам, механизм и дешёвая починка без генерации

15 октября 2026

Коротко

1. **Проблема.** Официальный драфт EAGLE-3 для Llama-3.1-8B-Instruct на 9 публичных дообучениях этой модели теряет **0–10%** τ после LoRA, **10–26%** после полного дообучения по домену и **40–60%** после дообучения под рассуждения: ускорение падает с 2,34× до 1,5×.
2. **Предсказание без генерации.** Потерю видно по одним весам: среднее относительное изменение матриц, пишущих в остаточный поток, коррелирует с ней с **r = 0,98** (ρ = 0,87, 9 моделей). По сдвигу скрытых состояний — r = 0,93.
3. **Механизм.** «Драфт сам подстраивается, потому что читает признаки target» — неверно в чистом виде. Новые признаки **одновременно** передают драфту новое поведение (+6…+23 п.п. там, где target изменил ответ) и **искажают** его работу там, где target ответ не менял (до −19 п.п. у тяжёлых изменений). Искажение идёт на 75–80% через последний читаемый слой и сосредоточено в 1–4 направлениях.
4. **Метод.** Поправка ранга 2 на слой, встроенная в W_{fc} драфта и подобранная за 1 минуту по прямым проходам двух моделей (без генерации новым target и без обучения драфта): **+8,6%** и **+9,6%** τ дерева на двух моделях с рассуждениями (95% интервалы выше нуля), +0,2% на контроле, но −9,7% на abliterated.

1 Постановка

Драфт EAGLE-3. Target с параметрами θ на позиции t даёт скрытые состояния $h_t^{(\ell)}(\theta)$. Драфт читает три слоя $\ell \in \{2, 16, 29\}$ (входы слоёв) и сжимает их линейным слоем

$$u_t = W_{\text{fc}}\left[h_t^{(2)};\, h_t^{(16)};\, h_t^{(29)}\right], \qquad W_{\text{fc}} \in \mathbb{R}^{4096\times 12288}.$$

Далее один слой декодера (u поступает и в нормированное внимание, и напрямую в остаточный поток драфта) и голова на 32 000 частых токенов. Драфт предлагает дерево из 60 токенов глубины 7, target проверяет его за один проход. τ — среднее число принятых токенов за проход target. Генерация жадная, поэтому без потерь качества.

Устаревание. Target дообучают: $\theta_0 \to \theta_1$, драфт ϕ_0 остаётся прежним. Потеря на области d:

$$L_d(\theta_1) = 1 - \frac{\tau_d(\phi_0; \theta_1)}{\tau_d(\phi_0; \theta_0)}.$$

Вопросы. (1) насколько велика L на реальных дообучениях; (2) можно ли предсказать её без генерации; (3) почему драфт не подстраивается; (4) можно ли починить драфт без генерации новым target и без обучения.

Что пробовали раньше (7–13 октября). На LoRA (Qwen3-8B, Llama-3.1-8B) поправка драфта под конкретное изменение оказалась малой (+0,03…+0,10 τ) по сравнению с общей докалибровкой; Procrustes, ridge и малые базисы её не воспроизводили (≤5% действия). Вывод: LoRA слишком слабо меняет target, нужны тяжёлые изменения — отсюда карта.

2 Карта устаревания

Протокол. Код авторов EAGLE (коммит `cb7e084`), официальный драфт `yuhuili/EAGLE3-LLaMA3.1-Instruct-8B`, дерево 60/7/10, жадно, до 512 новых токенов; 96 запросов: по 16 из общих вопросов, математики, кода, медицины, вызовов инструментов (ToolACE) и русского (m-ArenaHard). Colab A100 80GB. Ускорение — на 12 запросах.

Target	тип изменения	общее	матем.	код	медиц.	инстр.	рус.	ускор.
Llama-3.1-8B-Instruct	—	5,71	6,13	6,44	5,15	3,95	1,67	2,34
LIMO	LoRA r8	5,31	5,54	6,42	4,98	3,82	1,64	1,93
ToolACE-8B	полное (≈ LoRA)	4,96	5,23	5,87	5,09	3,65	1,59	2,09
SuperNova-Lite	дистилляция	5,03	5,12	5,91	4,85	3,14	1,47	1,87
Vikhr (рус.)	полное	4,63	5,17	5,84	4,61	3,39	1,53	2,02
UltraMedical	полное	4,26	5,02	5,42	4,45	4,05	1,45	1,87
HuatuoGPT-o1	полное, рассуждения	4,45	4,51	4,84	4,14	4,28	3,41*	2,87
abliterated	тяжёлое	3,38	3,41	4,36	4,02	2,87	2,27	2,24
R1-Distill	дистилляция рассуждений	2,82	3,12	3,00	3,20	2,83	1,35	1,74
Nemotron-Nano	рассуждения, SFT+RL	2,49	2,60	2,55	2,96	2,30	1,57	1,51
R1-Distill, *свой* драфт	—	6,16	7,34	6,13	5,13	2,09	1,47	2,37
Instruct, драфт R1	—	2,05	2,58	2,35	2,19	1,77	1,34	1,30

Таблица 1: τ дерева. *HuatuoGPT-o1 отвечает на русские вопросы по-английски (7% кириллицы). На русском у исходной модели 56% токенов ответа вне словаря драфта и 93% обрывов цепочки происходят на них.

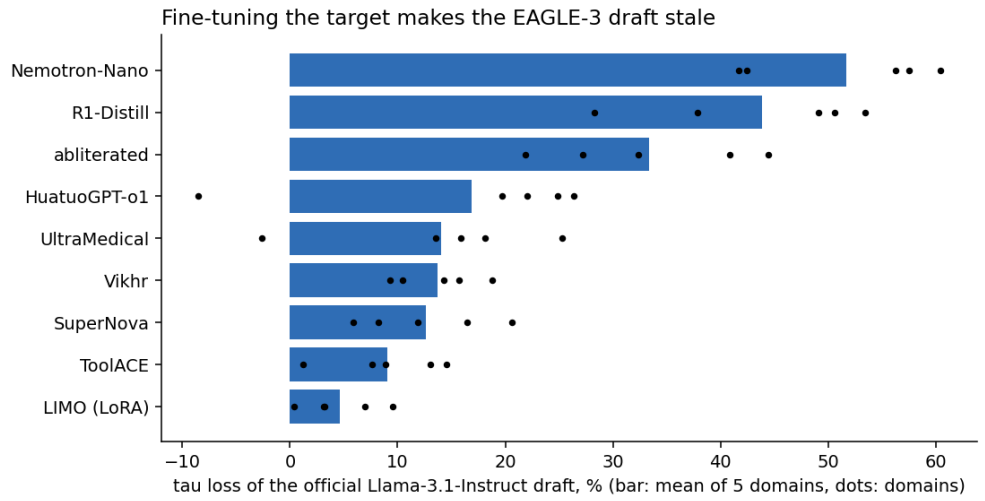


Рис. 1: Средняя потеря τ по 5 английским областям (столбцы) и по областям (точки).

Выводы. LoRA: 0–10%; полное дообучение по домену: 1–26% во *всех* областях, не только в «своей»; тяжёлые изменения и рассуждения: 22–60%. Собственный драфт возвращает всё (2×2 с R1-Distill), значит потеря — несоответствие драфта, а не свойство модели. Обучающие данные драфта тоже важны: на вызовах инструментов собственный драфт R1-Distill хуже драфта Instruct (2,09 против 2,83).

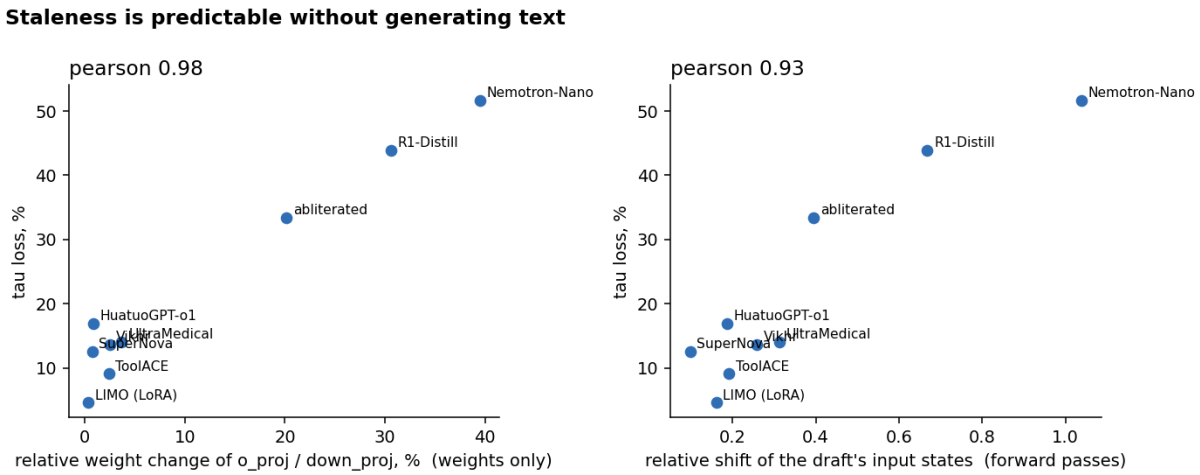
3 Предсказание устаревания без генерации

Для каждого изменения на общих текстах (ответы исходной модели на 48 запросов) считаем

$$\delta = \mathbb{E}_t \frac{\|h_t(\theta_1) - h_t(\theta_0)\|}{\|h_t(\theta_0)\|} \quad \text{(прямые проходы)},$$

$$\rho_W = \text{mean}_{W \in \{o,\, down\}} \frac{\|W_1 - W_0\|_F}{\|W_0\|_F} \quad \text{(только веса)}.$$

Предсказатель потери τ (9 изменений)	Пирсон [95%]	Спирмен	ошибка LOO
ρ_W, веса o_proj/down_proj (**только веса**)	**0,98**	0,87	—
сдвиг состояний δ, три слоя	0,93 [0,55; 0,98]	0,83	7,7 п.п.
сдвиг состояний, слой 29	0,94 [0,65; 0,99]	0,90	7,1 п.п.
KL драфта (новые против старых признаков)	0,93 [0,78; 0,99]	0,90	6,6 п.п.
изменение поведения target (доля argmax)	0,86	0,78	9,4 п.п.
константа	—	—	13,8 п.п.



Оговорки. Корреляцию держат три тяжёлых изменения; без двух моделей с рассуждениями r = 0,75 (ρ = 0,64). Умеренные дообучения точно не ранжируются: HuatuoGPT-o1 меняет веса меньше чем на 1%, но теряет 17%. Это фильтр «сломается ли драфт сильно», а не точный прогноз. Сдвиг состояний предсказывает лучше, чем изменение поведения самого target.

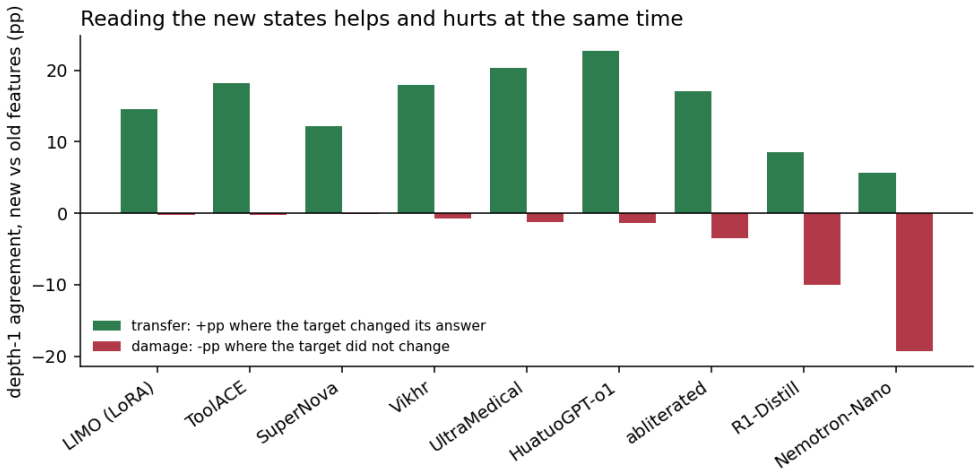
Как меняются веса. LIMO и ToolACE — низкоранговые изменения (32 направления несут 89% и 99,5% энергии ΔW); остальные плотные (5–58%). Направления, в которых веса пишут в остаточный поток (по 8 главных левых сингулярных векторов ΔW_o, ΔW_{down} предыдущих слоёв), содержат **21–66%** среднего сдвига состояний в слое 29 против 7–13% у случайного подпространства той же размерности: веса подсказывают, куда сдвинутся признаки. R1-Distill и Nemotron-Nano (разные команды, разные стартовые точки) сдвигают состояния в общем направлении: косинус средних сдвигов 0,5–0,86, устойчиво к исключению «массивных» измерений.

4 Механизм: перенос против искажения

На общем тексте делим позиции по тому, изменил ли target свой следующий токен: $y_t^1 = y_t^0$ (множество S) или $y_t^1 \neq y_t^0$ (множество C). Совпадение драфта на первом шаге, когда он читает признаки f:

$$a_X(f) = \Pr_{t \in X}\left[\arg\max q_{\phi_0}(\cdot \mid f_{\le t}) = y_t^1\right], \qquad \underbrace{T = a_C(f^1) - a_C(f^0)}_{\text{перенос}}, \qquad \underbrace{D = a_S(f^0) - a_S(f^1)}_{\text{искажение}}.$$

	LIMO	ToolACE	SuperN.	Vikhr	UltraM.	Huatuo	ablit.	R1-D.	Nemotron
доля C, %	5,1	4,5	3,3	7,3	8,4	7,2	7,2	16,4	14,5
перенос T, п.п.	+14,5	+18,2	+12,2	+18,0	+20,4	+22,7	+17,0	+8,5	+5,6
искажение D, п.п.	0,3	0,2	0,2	0,8	1,2	1,4	3,4	10,0	19,3



- У умеренных изменений потеря — это сами изменения поведения (C: 3–8% токенов, драфт угадывает их лишь в 45% случаев); признаки драфт почти не портят.
- У тяжёлых изменений добавляется искажение на S — 85–95% токенов, где ответ target прежний. Оно бьёт по частым служебным токенам (the, запятая, точка), а не по содержанию, и затрагивает все токены.
- **Не масштаб, а направление.** У рассуждающих моделей $\cos(h^0, h^1) = 0{,}68$–$0{,}81$, чистое масштабирование объясняет 2–15% сдвига. Через W_{fc} драфт видит сдвиг на 73–80% из слоя 29, на 25% из слоя 16 и почти не видит из слоя 2.
- Отсюда старая формулировка «бесплатного переноса нет»: в сумме по токенам T и D компенсируют друг друга.

5 Метод: избирательное восстановление входа драфта

Цель — убрать искажение D, сохранив перенос T. Восстановление строится как функция только новых признаков и подгоняется по прямым проходам θ_0 и θ_1 на 24 текстах исходной модели (половина общих текстов; λ — на отложенной четверти).

Поправка (зафиксирована до проверки τ). Для каждого читаемого слоя j: средний сдвиг μ_j и главное направление v_j центрированного сдвига, $P_j = \text{orth}[\mu_j; v_j] \in \mathbb{R}^{2\times 4096}$. Ridge-регрессия предсказывает, насколько вернуть координаты вдоль P_j:

$$\min_{R_j} \left\| (X^0 - X^1)P_j^\top - [X^1, \mathbf{1}]R_j \right\|_F^2 + \lambda \|R_j\|_F^2, \qquad x' = x + [x, 1]R_j P_j = x\,(I + A_j) + c_j,$$

где $A_j = R_j^{(1:H)} P_j$ (ранг 2), $c_j = R_j^{(H+1)} P_j$. Встраиваем в драфт:

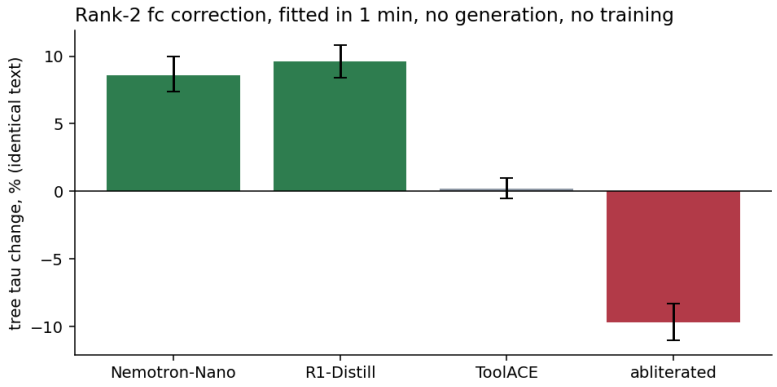
$$W'_{\text{fc}} = W_{\text{fc}}\,\text{blockdiag}\big(I + A_2^\top,\, I + A_{16}^\top,\, I + A_{29}^\top\big), \qquad b_{\text{fc}} = W_{\text{fc}}\,[c_2; c_{16}; c_{29}].$$

Стоимость: прямые проходы двух моделей на 10 тыс. токенов и три решения линейных систем, около минуты на A100. Новый target ничего не генерирует, драфт не обучается.

Выбор варианта (первый шаг драфта, тестовая половина). 30 вариантов: среднее, поэлементное аффинное, $k \in \{1, 4, 16, 64\}$ направлений сдвига, разные наборы слоёв. Лучшие возвращают 47–57% разрыва $a(f^0) - a(f^1)$; лучшим оказывается 1–4 направления, а не 64 — искажение почти одномерно. Перенос при этом сохраняется: у Nemotron на C совпадение 0,281 → 0,320 (со старыми признаками 0,204).

Изменение τ дерева с поправкой	общее начало ответов	95% интервал	запросов лучше / хуже	по областям
Nemotron-Nano	**+8,6%**	[+7,4; +10,0]	94% / 3%	+6,5…+11,2%
R1-Distill	**+9,6%**	[+8,4; +10,8]	90% / 10%	+3,9…+10,7%
ToolACE (контроль)	+0,2%	[−0,5; +1,0]	24% / 33%	−2,3…+4,8%
abliterated	−9,7%	[−11,0; −8,3]	3% / 89%	−12,2…−7,8%

Таблица 2: Протокол карты, ответы самого изменённого target. Тексты с поправкой и без не всегда побуквенно одинаковы (bf16-проверка дерева иначе разрешает почти равные варианты), поэтому сравнение — на общем начале ответов до первого расхождения (43–80% длины). Русский: без изменений.



Выигрыш идёт за счёт меньшей доли пустых циклов (Nemotron 23% → 20%) и большего числа длинных цепочек, равномерно по ответу. При неизменной стоимости цикла ускорение растёт 1,51× → 1,65× (Nemotron) и 1,74× → 1,86× (R1-Distill).

Почему abliterated хуже. Там искажение в основном *масштабное*: $\|u^1\|/\|u^0\| = 0{,}79$, поворот слабый ($\cos(u^0, u^1) = 0{,}94$), 45% сдвига состояний — чистое масштабирование. Выход fc идёт в остаточный поток драфта без нормировки, так что масштаб важен, а поправка рассчитана на поворот. Прокси на первом шаге обещал здесь лишь +0,011 и не увидел вреда. **Гипотеза правила:** включать поправку при медиане $\cos(u^0, u^1) < 0{,}9$ — отделяет помогающие случаи (0,75; 0,82) от остальных (0,94; 0,99). Подобрано задним числом по 4 точкам.

6 Новизна и связанные работы

- **EDA** (2026): адаптация драфта к дообученному target через генерацию и обучение; у нас — без генерации и обучения. **AngelSpec**, **Draft-OPD**: драфт режима без рассуждений хуже на режиме с рассуждениями (смена режима, не весов). **SPEED-Bench**, **AdaSpec**, **SpecVocab**: урезанный словарь вредит неанглийским языкам — наши цифры по русскому это подтверждают.
- Не найдено в литературе: предсказание устаревания драфта по весам изменения; разложение «перенос против искажения» с прямым замером; починка входа драфта из прямых проходов без генерации.

7 Ограничения и следующие шаги

- Одна база (Llama-3.1-8B) и один драфт; 16 запросов на область; метод проверен на 4 изменениях, правило включения — задним числом. Ускорение по времени оценено через τ, а не измерено.
- **Следующие шаги:** (1) заранее объявленная проверка на 2–3 новых моделях с рассуждениями с правилом $\cos < 0{,}9$ и замером скорости (1,5 ч A100); (2) вторая семья моделей (Qwen3-8B); (3) поправка, учитывающая масштаб (для abliterated); (4) веса как источник направлений поправки — шаг к версии «только по весам».