Устаревание драфта EAGLE после дообучения target

Карта, предсказание по весам, механизм и дешёвая починка без генерации

15 октября 2026

Проблема

- EAGLE-3 ускоряет генерацию в 2–4 раза, но драфт обучают под конкретный target.
- Target постоянно дообучают: LoRA под домены, SFT, RL, дистилляция рассуждений.
- Драфт остаётся старым. Переобучение (EDA и аналоги) — генерация новым target и часы обучения.

Вопросы

1. Насколько драфт устаревает на реальных дообучениях?
2. Можно ли это предсказать, не генерируя текст?
3. Почему драфт не подстраивается сам, хотя читает признаки target?
4. Можно ли починить драфт **без генерации и без обучения**?

Постановка

Драфт читает три слоя target и сжимает их:

$$u_t = W_{\text{fc}}\left[h_t^{(2)};\, h_t^{(16)};\, h_t^{(29)}\right], \qquad W_{\text{fc}} \in \mathbb{R}^{4096\times 12288}$$

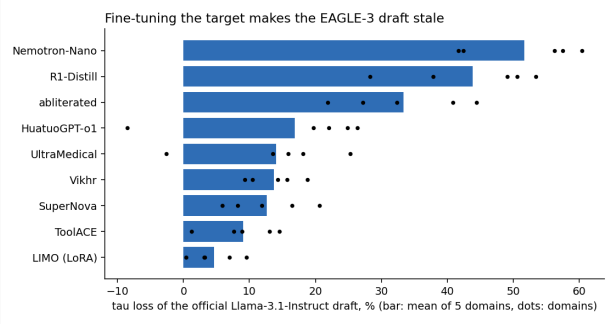
Дерево 60 токенов глубины 7, τ — принятых токенов за проход target.

Target дообучили: $\theta_0 \to \theta_1$, драфт ϕ_0 прежний. Потеря на области d:

$$L_d(\theta_1) = 1 - \frac{\tau_d(\phi_0; \theta_1)}{\tau_d(\phi_0; \theta_0)}$$

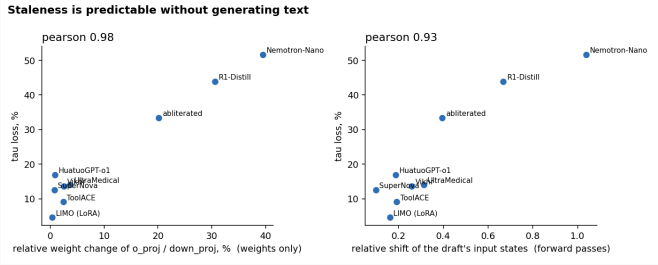
Протокол: код авторов EAGLE, официальный драфт Llama-3.1-8B-Instruct, 96 запросов (общие, математика, код, медицина, инструменты, русский), 10 публичных дообучений, Colab A100.

1. Дообучение делает драфт устаревшим



- LoRA: **0–10%**
- полное по домену: **10–26%**, во всех областях
- рассуждения: **40–60%**, ускорение $2{,}34\times \rightarrow 1{,}5\times$
- свой драфт R1-Distill возвращает всё ⇒ дело в несоответствии драфта
- русский: 56% токенов вне словаря драфта, $\tau = 1{,}67$

2. Устаревание видно без генерации



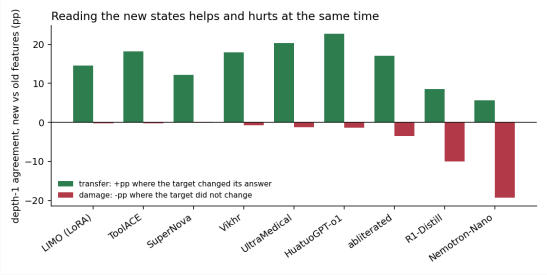
$$\rho_W = \text{mean}_{o,down} \frac{\|W_1 - W_0\|_F}{\|W_0\|_F}$$

- только веса: **r = 0,98**, ρ = 0,87
- сдвиг состояний: r = 0,93
- лучше, чем изменение поведения target (0,86)
- *Оговорка:* держится на тяжёлых изменениях; умеренные не ранжирует

3. Механизм: перенос против искажения

Делим токены: target **не изменил** ответ (S) или **изменил** (C). Совпадение драфта на первом шаге:

$$T = a_C(f^1) - a_C(f^0) \ \text{(перенос)}, \qquad D = a_S(f^0) - a_S(f^1) \ \text{(искажение)}$$



- перенос есть везде: +6…+23 п.п.
- искажение только у тяжёлых: −3…−19 п.п.
- «драфт сам подстраивается» = $T - D$, у тяжёлых ≈ 0
- искажение — **направление**, не масштаб; 75–80% через слой 29; бьёт по служебным токенам

4. Где живёт искажение

- Поэлементное, полноранговое и низкоранговое восстановление «новые → старые признаки»: **30 вариантов**.
- Лучшее возвращает **47–57%** разрыва на первом шаге драфта — и это 1–4 направления, а не 64.
- Перенос сохраняется: у Nemotron на C $0{,}281 \rightarrow 0{,}320$ (со старыми признаками $0{,}204$).
- Вторая половина искажения специфична для токенов и линейно не возвращается.

Вывод
Глобальная часть искажения почти одномерна ⇒ её можно убрать поправкой ранга 1–2 на слой.

5. Метод: поправка ранга 2, встроенная в W_{fc}

Для слоя j: $P_j = \text{orth}[\mu_j; v_j]$ — средний сдвиг и главное направление сдвига. Ridge:

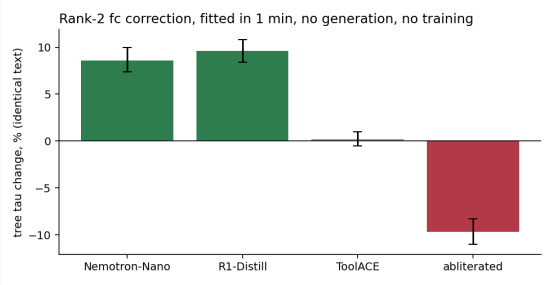
$$\min_{R_j} \left\| (X^0 - X^1)P_j^{\top} - [X^1, \mathbf{1}]R_j \right\|_F^2 + \lambda \|R_j\|_F^2, \qquad x' = x(I + A_j) + c_j, \ \text{rank}\, A_j = 2$$

Встраиваем в драфт:

$$W'_{\text{fc}} = W_{\text{fc}} \,\text{blockdiag}\left(I + A_j^{\top}\right)_{j=2,16,29}, \qquad b_{\text{fc}} = W_{\text{fc}}\,[c_2; c_{16}; c_{29}]$$

- данные: прямые проходы θ_0 и θ_1 на 24 текстах исходной модели
- **новый target ничего не генерирует, драфт не обучается**, 1 минута на A100
- вариант зафиксирован **до** проверки τ

6. Результат: τ дерева на ответах самого изменённого target



	$\Delta\tau$	95% интервал
Nemotron-Nano	**+8,6%**	[+7,4; +10,0]
R1-Distill	**+9,6%**	[+8,4; +10,8]
ToolACE (контроль)	+0,2%	[−0,5; +1,0]
abliterated	−9,7%	[−11,0; −8,3]

- лучше 90–94% запросов у рассуждающих моделей
- ускорение ≈ $1{,}51 \rightarrow 1{,}65\times$ и $1{,}74 \rightarrow 1{,}86\times$
- сравнение на общем начале ответов

Почему не везде: когда включать поправку

	поворот выхода fc, $\cos(u^0, u^1)$	масштаб, $\|u^1\|/\|u^0\|$	эффект
Nemotron-Nano	0,75	1,49	+8,6%
R1-Distill	0,82	1,13	+9,6%
abliterated	0,94	0,79	−9,7%
ToolACE	0,99	1,05	+0,2%

- у рассуждающих моделей искажение — **поворот**: на него поправка и рассчитана
- у abliterated — **сжатие**; u идёт в остаточный поток драфта без нормировки
- гипотеза правила: включать при $\cos(u^0, u^1) < 0{,}9$ (4 точки, задним числом)

Новизна

Уже известно	Наше
EDA: адаптация драфта к дообученному target через генерацию и обучение	починка входа драфта **из прямых проходов**, без генерации и обучения
AngelSpec, Draft-OPD: драфт режима без рассуждений хуже на рассуждениях	то же для **изменения весов**: −40…−60%; систематическая карта на 10 моделях
SPEED-Bench, AdaSpec, SpecVocab: урезанный словарь вредит языкам	**предсказание устаревания по весам** (r = 0,98)
«EAGLE подстраивается сам, т.к. читает признаки»	разложение **перенос против искажения**, искажение почти одномерно

Выводы

1. Дообучение, особенно под рассуждения, съедает 40–60% выгоды EAGLE.
2. Устаревание **предсказуемо по весам** — без текстов и прогонов.
3. Новые признаки передают драфту новое поведение, но у тяжёлых изменений **искажают** его работу; искажение почти одномерно.
4. Поправка ранга 2 за минуту, без генерации и обучения: **+9–10% τ** на моделях с рассуждениями.
5. Это «первая помощь»: свой драфт даёт +100%; поправка не универсальна (abliterated).

Ограничения и следующие шаги

Ограничения

- одна база (Llama-3.1-8B), один драфт
- 16 запросов на область
- метод проверен на 4 изменениях; правило — задним числом
- ускорение по времени оценено через τ

Дальше

- заранее объявленная проверка на 2–3 новых рассуждающих моделях + замер скорости (1,5 ч A100)
- вторая семья: Qwen3-8B
- поправка, учитывающая масштаб
- направления поправки из весов — шаг к версии «только по весам»