

EAGLE-3: дополнительные проверки

Языки, публичные драфты, архитектура против данных, воспроизводимость, обзор литературы

Смена по воспроизведению EAGLE-3

7 октября 2026

Главное на одной странице

Исследование слоёв target и MoE на входе драфта описано в отдельном отчёте и здесь не повторяется.

- Языки.** На неанглийских языках ускорение почти исчезает. Официальный драфт DSL-8B: $3,5\times$ на английском, $1,1\times$ на русском, $0,67\times$ на японском (медленнее обычной генерации). Главная причина — урезанный словарь драфта (32 тыс. токенов): вне него 33–61 % токенов ответа, и $\tau \leq 1/p$.
- Сдвиг распределения без изменения весов.** У одного и того же target (Qwen3-8B) включение режима рассуждений стоит публичным драфтам от 4 до 33 % длины принятия. Величина потери зависит от того, на каких текстах учили драфт.
- Данные важнее архитектуры.** Драфты на одних данных, но с разной архитектурой (EAGLE-3 / 3.1, разные варианты attention, lr) совпадают по τ с точностью $\pm 0,02$. Публичные драфты разных команд для одного target различаются почти вдвое (τ 2,6–4,8).
- Геометрия.** Независимые драфты «читают» из признаков target похожие направления (в 10–40 раз чаще случайного) и почти весь сигнал берут из верхнего слоя. Сравнивать драфты по сырым весам бессмысленно: близкие по поведению драфты имеют сильно разные веса.
- Воспроизводимость.** Стенд воспроизводит τ статьи с точностью 5–12 %. Найдено расхождение в официальном скрипте оценки: ответы обрезаются на 512 токенах вместо заявленных 1024.

1 Стенд, протокол и метрики

Target	Драфт(ы)	Слои по умолчанию
DeepSeek-R1-Distill-Llama-8B (DSL-8B), $N = 32$	официальный драфт авторов EAGLE-3	(2, 16, 29)
Qwen3-1.7B, $N = 28$	AngelSlim (сторонний)	(2, 14, 25)
Qwen3-8B, $N = 36$	11 публичных драфтов разных команд (раздел 3)	(2, 18, 33) и др.

Метрика. Средняя длина принятия τ — сколько токенов принимается за один цикл «драфт → проверка», включая бонусный токен target. Интервалы — paired bootstrap по вопросам.

Протокол. Как в официальном скрипте авторов: первый ход вопроса, без system prompt, temperature 0, дерево total 60 / depth 5 / top-k 10, до 512 новых токенов, MT-bench + GSM8K (+ HumanEval). Одина H200, bf16, EAGLE commit cb7e084.

Свой офлайн-оценщик. Чтобы сравнивать драфты любых форматов (EAGLE, speculators/vLLM, DeepSeek), мы написали оценщик, который воспроизводит генерацию драфта вдоль greedy-продолжения target и моделирует циклы проверки. Сверка с настоящей цепочечной генерацией EAGLE: τ 2,395 против 2,406 (расхождение 0,5 %); первый шаг совпадает с кодом EAGLE на 100 %.

DSL-8B, официальный драфт	MT-bench	GSM8K	HumanEval
Статья, Табл. 1	5,58	6,93	6,38
Наш станд (H200, bf16)	5,28	6,08	5,84

Таблица 1: Сверка со статьёй: отличие 5–12 %. Повторный прогон даёт побитово те же токены.

2 Языки

Одни и те же 60 вопросов m-ArenaHard и 60 задач MGSM на шести языках, протокол статьи.

Язык	DSL-8B (официальный драфт)			Qwen3-1.7B (AngelSlim)		
	τ	вне словаря	ускорение	τ	вне словаря	ускорение
английский	5,34	1,5 %	3,52×	3,65	3,2 %	2,25×
немецкий	2,85	17 %	1,93×	2,41	16 %	1,45×
китайский	1,85	48 %	1,28×	2,15	33 %	1,34×
японский	1,97	42 %	0,67×	1,77	43 %	1,07×
русский	1,62	56 %	1,11×	1,71	49 %	1,13×
украинский	1,88	44 %	1,18×	1,44	61 %	0,88×

Таблица 2: «Вне словаря» — доля токенов ответа, которых нет в 32-тысячном словаре драфта. Ускорение — реальное время на подвыборке.




Рис. 1: Слева: τ и реальное ускорение по языкам. Справа: τ против доли токенов вне словаря; пунктир — потолок $1/p$.

Почему. Чтобы драфт работал быстрее, его выходной слой урезан до 32 тыс. самых частых токенов обучающих данных (англоязычные ShareGPT/UltraChat). Русские, украинские и иероглифические токены в эти данные почти не попадают. Цепочка драфта обрывается на первом токене вне словаря, поэтому даже идеальный в остальном драфт даёт не больше $\tau \approx 1/p$ токенов за цикл, где p — доля таких токенов. На русском до 93 % обрывов цепочки вызваны именно ими.

3 Публичные драфты для одного target: архитектура, данные, геометрия

Для Qwen3-8B скачаны 11 публичных EAGLE-3 драфтов (AngelSlim, Tengyunw, thoughtworks, RedHat, RedHat-Thinking, DeepSeek, 5 вариантов inference-optimization). Все оценены нашим офлайн-оценщиком на одних и тех же 240 вопросах в двух режимах работы target: без рассуждений и с рассуждениями. Веса target в обоих режимах одинаковы.




Рис. 2: Цепочечная τ (до 6 шагов). Подписи — изменение при включении режима рассуждений.

Наблюдения.

- **Сдвиг распределения ломает драфт и без изменения весов target.** Сильнее всего теряют DeepSeek (−33 %), thoughtworks (−18 %) и RedHat (−16 %; по карточке обучен без рассуждений). Семейство inference-optimization и RedHat-Thinking (обучен с рассуждениями) теряют 4–7 %.
- **Данные важнее архитектуры.** Пять драфтов inference-optimization обучены на одних данных, но отличаются архитектурой (EAGLE-3 / EAGLE-3.1 с нормализацией входа, Llama / Qwen3 attention) и learning rate. Их τ совпадают с точностью $\pm 0,02$ (вариант с fc_norm −0,2). Нормализация входов EAGLE-3.1 у полностью обученных драфтов выигрыша не даёт.
- **Качество драфтов для одного target различается почти вдвое:** τ от 2,6 до 4,8. Выбор публичного драфта влияет на ускорение не меньше, чем методы оптимизации.
- **Пятислойный драфт DeepSeek** — лучший без рассуждений (4,78). Он читает 60 % сигнала из слоя 34 и 31 % из слоя 26 ($\approx 0,72N$), что независимо согласуется с выводом отдельного отчёта о слое $0,7N$.




Рис. 3: Слева: насколько совпадают главные направления, которые fc читает из слоя 33 target (1 — полностью, случайные подпространства дали бы $\approx 0,016$). Справа: откуда fc берёт сигнал на реальных данных; чёрные метки — та же доля, посчитанная только по весам.

Геометрия (величины, не зависящие от внутренних симметрий драфта).

- **Общее «пространство чтения».** Независимые драфты читают из признаков target похожие направления: перекрытие 0,2–0,6 против 0,016 у случайных. Драфты с общей стартовой точкой (семейство inference-optimization) — 0,5–0,9.
- **Верхний слой.** На реальных данных 80–96 % сигнала fc приходит из слоя $N - 3$ и около 1 % из слоя 2 у всех драфтов. По весам картина совсем другая (доля блока слоя 2 — от 9 до 64 %): веса без учёта масштаба активаций вводят в заблуждение.
- **Выходная голова привязана к target.** У драфтов inference-optimization и DeepSeek выходная голова совпадает с головой target (СКА = 1,00), то есть выход драфта живёт в пространстве последнего слоя target.
- **Веса $\neq$ функция.** У драфтов с общей стартовой точкой косинус весов 0,3–0,7 при почти одинаковой τ . Сравнивать и переносить нужно функциональные величины, привязанные к target, а не сырые веса.

4 Воспроизводимость и найденные ошибки

- Официальный скрипт оценки не передаёт `--max-new-token 1024` в генерацию: фактически ответы обрезаются на 512 токенах. Для рассуждающих моделей ответ почти всегда обрывается на середине.
- Обучающий код EAGLE-3 не запускается без правки: обращение `.gradient_checkpointing` к словарю конфигурации (исправлено коллегами).
- В обучающем коде RoPE драфта всегда с базой 10 000, а инференс берёт `rope_theta` из конфига драфта, если он там указан.
- Номера слоёв у разных реализаций означают разное: в EAGLE и speculators — вход слоя, у DeepSeek — выход (проверено по τ : 4,78 против 4,60).
- При вычислениях в bf16/fp16 greedy-тексты с разными драфтами расходятся на поздних токенах; «без потерь» выполняется математически, но не побитово.

5 Обзор литературы

5.1 Семейство EAGLE и словарь драфта

- **EAGLE / EAGLE-2 / EAGLE-3** (Li et al., 2024–2025): драфт из одного слоя на признаках target; в EAGLE-3 — смесь трёх уровней и training-time test. Единственная абляция входа — тройка против последнего слоя.
- **EAGLE-3.1** (vLLM, 2026): нормализация каждого входа f_c — совпадает с нашим наблюдением о масштабе.
- **FR-Spec** (ACL 2025): урезание словаря драфта по частотам, LM head дешевле на 75 %, $1,12\times$ к EAGLE-2. Влияние на языки, которых мало в данных, не изучено.
- **T-pro 2.0** (Т-Банк, arXiv 2512.10430): EAGLE-подобный драфт (один слой + FR-Spec) для русской модели с токенизатором под кириллицу; τ 3,2–4,1 и ускорение 1,6–2,3 $\times$ на русских бенчмарках. Сравнения одного драфта на разных языках нет.

5.2 Языки

- **Paudel et al., 2026** (arXiv 2605.30580): на 11 языках speculative decoding заметно хуже для малоресурсных языков; причина — слабая многоязычность маленьких драфтов; предлагают n-граммные драфты.
- **Sandler et al., 2025** (arXiv 2510.02128): ускорение распределено неравномерно и проседает на слабо представленных задачах.
- **Yi et al., 2024** (arXiv 2406.16758): драфты, дообученные под язык, ускоряют генерацию на этом языке.
- Наш вклад: для EAGLE-3 главная причина — словарь драфта, с простым потолком $\tau \leq 1/p$.

5.3 Архитектура и размер драфта

- **Meta, 2025** (arXiv 2508.08192): глубина EAGLE-драфта $1 \rightarrow 3$ слоя даёт +9 % к числу токенов за цикл, глубже — плато; в продакшене 3-слойный драфт для Llama 3/4.
- **KOALA, 2024** (arXiv 2408.08146): многослойные головы драфта, +10–14 % скорости.
- **Decoding Speculative Decoding** (Yan et al., NAACL 2025): задержку драфта определяет глубина, а не ширина; широкие мелкие драфты дают до +60 % пропускной способности; точность драфта как LM слабо связана с ускорением.
- **Законы масштабирования** (Yan et al., 2025, arXiv 2505.07858; SDSL, 2026, arXiv 2603.11053; LREC-COLING 2024): доля принятия растёт лог-линейно с данными и размером драфта; типичный драфт в 10–20 раз меньше target.
- Для EAGLE-драфтов размер почти не нужно масштабировать вместе с target: в статье EAGLE-3 один слой даёт τ 6,23 на 8B и 5,88 на 70B; у Meta 3 слоя работают от 8B до MoE Llama 4.

5.4 Адаптация драфта к изменению target и перенос дельт весов

- **EDA** (Lin et al., 2026, arXiv 2603.09527): драфт базовой модели на дообученных Qwen2.5-Math, Qwen2.5-Coder и Meditron теряет τ с 4,37 до $\sim 1,2$; адаптация «общий + личный эксперт» на данных новой модели, 27,5 % параметров.
- **Online Speculative Decoding** (ICML 2024), **DVI** (2025), **OmniDraft** (2025): онлайн-дообучение драфта под поток запросов.

- **SD² / Steering Pretrained Drafters** (AAAI 2026): вектор управления из скрытых состояний target подмешивается в драфт без обучения, +22–35 % принятых токенов.
- **Turbo LoRA** (Predibase), **vLLM RFC #52038 / PR #55947**: свой адаптер драфта под каждый LoRA — инженерная практика.
- **Task arithmetic**: межъязыковой перенос (Parović et al., EACL 2024), перенос дельты дообучения между версиями модели (Lin et al., 2025, arXiv 2503.20110), перенос task vectors между архитектурами без обучения — **Theseus** (ICML 2026, arXiv 2602.12952).
- **ADAPT** (arXiv 2608.22854): дельта дистилляции переносится на учеников, собранных из слоёв разных версий учителя (у опубликованных моделей скопированы 19 из 36 слоёв Qwen3-4B).
- **Osprey** (arXiv 2609.09338): предобучение драфта, не привязанное к target, плюс лёгкая адаптация; лучшие приросты на многоязычных данных.