

Какие слои target-модели нужны драфту EAGLE-3

Исследование входа драфт-модели: абляции, развёртка по слоям, МоЕ

Смена по воспроизведению EAGLE-3

7 октября 2026

Кратко

1. **Нижний слой (2) почти ничего не даёт:** без него τ падает на 2 % (DSL-8B) и 6,5 % (Qwen3-1.7B), в сигнале fc его меньше 3 %.
2. **Верхний слой ($N - 3$) обязателен:** без него драфт теряет 40–68 % τ . Роль среднего слоя зависит от драфта: –30 % у DSL и –8 % у Qwen.
3. **Самый информативный одиночный слой лежит на глубине $\approx 0,7N$** в обеих моделях (23 из 32 и 20 из 28). Лучший второй слой к $N - 3$ тоже $\approx 0,7N$.
4. **$N - 3$ лучше последнего слоя:** последний специализирован на следующем токене, а драфту нужен горизонт в несколько токенов.
5. **На Qwen** нормализация входов и замена слоя $N/2 \rightarrow 0,7N$ дают +0,42 τ к переобученному upstream-входу при том же числе параметров.
6. **МоЕ на входе драфта выигрыша не даёт:** роутер сходится к фиксированному выбору, эксперты схлопываются.

1 Постановка

Target-модель имеет N декодерных слоёв и скрытый размер H . Обозначим через $h_\ell \in \mathbb{R}^H$ residual stream на входе слоя ℓ (h_0 — эмбединги, h_N — выход последнего слоя до финальной нормы). EAGLE-3 строит вход драфта как

$$g_t = W [h_2^{(t)}; h_{N/2}^{(t)}; h_{N-3}^{(t)}] = \underbrace{W_{\text{low}} h_2^{(t)}}_{c_{\text{low}}} + \underbrace{W_{\text{mid}} h_{N/2}^{(t)}}_{c_{\text{mid}}} + \underbrace{W_{\text{high}} h_{N-3}^{(t)}}_{c_{\text{high}}}, \quad W \in \mathbb{R}^{H \times 3H}. \quad (1)$$

Номера слоёв (2, $N/2$, $N - 3$) жёстко зашиты в коде и не зависят от модели. Драфт (один декодерный слой) получает g_t вместе с эмбедингом токена x_{t+1} и предсказывает x_{t+2} . Далее он работает авторегрессионно на собственных выходах. В статье единственная абляция (Табл. 2) сравнивает тройку слоёв с одним *последним* слоем.

Метрика. Основная метрика — средняя длина принятия τ : сколько токенов принимается за один цикл «драфт → проверка», включая бонусный токен target:

$$\tau = \frac{\sum_c (a_c + 1)}{\#\text{циклов}}, \quad a_c \text{ — число принятых драфт-токенов в цикле } c. \quad (2)$$

Разницы $\Delta\tau$ между условиями даются с 95 %-интервалом paired bootstrap по вопросам.

2 Стенд

Пара	Драфт	Слои upstream
DSL-8B (DeepSeek-R1-Distill-Llama-8B), $N = 32, H = 4096$	официальный, yuhui/EAGLE3-DeepSeek- R1-Distill-LLaMA-8B	(2, 16, 29)
Qwen3-1.7B , $N = 28, H = 2048$	сторонний, AngelSlim/Qwen3- 1.7B_eagle3	(2, 14, 25)

Протокол повторяет официальный скрипт оценки авторов: первый ход вопроса, без system prompt, temperature 0, дерево total 60 / depth 5 / top-k 10, до 512 новых токенов. Абляции считаются на MT-bench и GSM8K (по 80 вопросов). Одна H200, bf16, код EAGLE на commit cb7e084.

DSL-8B , официальный драфт	MT-bench	GSM8K	HumanEval
Статья, Табл. 1	5,58	6,93	6,38
Наш прогон	5,28	6,08	5,84

Таблица 1: Сверка базового τ со статьёй. Отличие 5–12 %; повторный прогон даёт побитово те же токены.

3 Методы

- Абляция средним.** Чтобы драфт «не видел» слой ℓ , его вектор заменяется средним по данным: $h_\ell \leftarrow \mathbb{E}[h_\ell]$. Веса драфта не меняются.
- Подмена слоя.** В слот подаётся соседний слой с выравниванием масштаба: $h_\ell \leftarrow h_{\ell'} \cdot \overline{\text{RMS}}(h_\ell) / \overline{\text{RMS}}(h_{\ell'})$.
- Вклад слоёв в fc .** Из разложения (1): доля энергии $s_k = \mathbb{E}\|c_k\|^2 / \sum_j \mathbb{E}\|c_j\|^2$.
- Развёртка по слоям.** Драфт заморожен. Для каждого слоя ℓ подбирается только линейный вход $A_\ell \in \mathbb{R}^{H \times H}$ (или $A \in \mathbb{R}^{H \times 2H}$ для пары $\{\ell, N-3\}$, у каждого входа RMSNorm), минимизируя первый шаг функции потерь EAGLE-3:

$$\mathcal{L}_0(A) = - \sum_t m_t \sum_{v \in \mathcal{V}_d} p_T(v \mid x_{\leq t+1}) \log q_D(v \mid A \text{ RMS}(h_\ell^{(t)}), e(x_{t+1})), \quad (3)$$

где p_T — распределение target на словаре драфта $\mathcal{V}_d$. Метрика — step-0 accuracy на ответах target (фиксированный текст). Обучение на 3000 ответах самой target-модели, как у авторов.

- Переобучение входа.** Как в п. 4, но для наборов слоёв, смесей и МоЕ-вариантов; 8000 ответов, 1000 шагов. Метрика — реальный τ .
- Пробы.** Для каждого слоя обучается линейная проба $\text{lm_head}(\text{norm}(h_\ell + B h_\ell + b))$, предсказывающая greedy-токен target через $k = 1, 2, 3$ шагов.

4 Результаты

4.1 На что опираются официальные драфты

Условие	DSL-8B ($\tau_0 = 5,62$)		Qwen3-1.7B ($\tau_0 = 3,55$)	
	τ	$\Delta, \%$	τ	$\Delta, \%$
без нижнего (2)	5,50	-2,2	3,32	-6,5
без среднего ($N/2$)	3,96	-29,6	3,26	-8,3
только $N - 3$	3,27	-41,8	2,88	-18,9
только 2 и $N/2$	3,33	-40,8	1,12	-68,4
$N/2 \rightarrow 0,7N$ (веса не менялись)	5,38	-4,3	3,38	-4,9
$N - 3 \rightarrow N - 1$	5,50	-2,2	3,05	-14,2
$N - 3 \rightarrow N$ (последний)	4,80	-14,6	2,16	-39,1
fc урезан до ранга $H/2$	5,51	-2,0	3,41	-3,9
fc урезан до ранга $H/4$	5,17	-8,0	2,87	-19,2

Таблица 2: Абляции официальных драфтов без переобучения (MT-bench + GSM8K, 160 вопросов). Все отличия значимы: ширина 95 %-интервала не больше $0,25 \tau$.




Рис. 1: Слева: доля s_k каждого слоя в g . Справа: рост нормы residual stream с глубиной, в 21 раз (DSL) и в 90 раз (Qwen) от слоя 2 до $N - 3$.

Интерпретация. fc получает слои без нормализации, а норма активаций растёт с глубиной на порядки (рис. 1). Поэтому верхний слой доминирует: $s_{\text{high}} = 65\%$ у DSL и 86% у Qwen. Нижний слой почти не используется ($s_{\text{low}} \leq 3\%$, отключение стоит 2–6 %). Официальный драфт DSL опирается на средний и верхний слои почти поровну, драфт Qwen — в основном на верхний. Замена $N - 3$ на последний слой бьёт сильнее, чем на $N - 1$: последний слой качественно отличается от предыдущих ($\text{СКА}(h_{N-3}, h_N) = 0,59$ у DSL и $0,45$ у Qwen).

4.2 Какой слой информативнее всего




Рис. 2: Слева: step-0 accuracy, когда драфт видит один слой. В центре: прирост от добавления второго слоя к $N - 3$. Справа: пробы на токен через k шагов. Ось X — глубина в долях N .

Драфт видит один слой	слой 2	$N/2$	лучший	$N - 3$	последний
DSL-8B	0,531	0,701	0,744 (23)	0,735	0,692
Qwen3-1.7B	0,511	0,569	0,661 (20)	0,629	0,570

Таблица 3: Развёртка по слоям: step-0 accuracy на ответах target, драфт заморожен.

Интерпретация. В обеих моделях максимум находится около $0,7N$, и это совпадает с пробами (рис. 2, справа). Информация о *следующем* токене ($k = 1$) растёт до самого верха сети, а о токенах на 2–3 шага вперёд достигает пика раньше, около $0,7N$. Драфт EAGLE предсказывает цепочку токенов, поэтому ему полезнее слой, где лучше представлено ближайшее будущее. Лучший партнёр для $N - 3$ — тоже $\approx 0,7N$: +1,5 п.п. у DSL и +6,0 п.п. у Qwen. Слой 2 в роли партнёра даёт −0,9 и +1,6 п.п.

4.3 Переобучение входа драфта (Qwen3-1.7B)

Вход драфта (драфт заморожен)	Параметры	τ	$\Delta\tau$ [95 % CI]
официальный fc, слои (2, 14, 25)	12,6М	3,60	—
(2, 14, 25) как в upstream, с нуля	12,6М	3,37	−0,23 [−0,28; −0,18]
(2, 14, 25) + RMSNorm	12,6М	3,68	+0,07 [0,04; 0,11]
(14, 20, 25) + RMSNorm	12,6М	3,80	+0,20 [0,16; 0,23]
(2, 20, 25) + RMSNorm	12,6М	3,79	+0,19 [0,15; 0,23]
пара (20, 25) + RMSNorm	8,4М	3,63	+0,03 [−0,01; 0,07]
только 25 ($N - 3$)	4,2М	3,22	−0,38 [−0,43; −0,34]
только 28 (последний)	4,2М	3,12	−0,48 [−0,53; −0,43]
смесь всех 29 слоёв (softmax-веса)	12,6М	3,75	+0,15 [0,12; 0,19]

Таблица 4: Qwen3-1.7B: обучается только вход, 8000 ответов target, 1000 шагов. $\Delta\tau$ к официальному fc.

Нормализация входов даёт +0,30 τ , замена $14 \rightarrow 20$ ещё +0,12 [0,10; 0,15]. Выученная смесь всех слоёв сама собирает веса у слоёв 18–22 и 25, но фиксированная тройка (14, 20, 25) не хуже смеси. Результат воспроизводится в двух независимых запусках (Kaggle T4 и H200, разные данные).

Ограничение для DSL. Официальный драфт обучен вместе со своим fc на многошаговой цели (training-time test). Подгонка одного fc по $\mathcal{L}_0$ не догоняет оригинал (−14 ... −32 % τ), поэтому сравнивать наборы слоёв на DSL по τ нельзя. Для DSL выводы опираются на табл. 2 и 3. Дообу-

чение официального τ даёт $+0,80 \tau$ на Qwen и 0 на DSL: прирост на Qwen объясняется недообученностью стороннего драфта.

4.4 МоЕ

Вариант (те же 12,6М параметров)	Наблюдение	$\Delta\tau$, Qwen
роутер по слоям для каждого токена	сходится к фиксированному выбору (слои 20 и 25); на DSL хуже статической смеси	$+0,03$ к смеси
low-rank МоЕ, 4 эксперта, top-1	эксперты схлопываются: 85 % токенов у одного (DSL: 99,8 %)	$-0,01 \pm 0,03$
то же с балансировкой нагрузки	нагрузка 22–26 % на эксперта, качество не выросло	$-0,04$

Таблица 5: МоЕ на входе драфта. Сравнение МоЕ с плотным low-rank входом того же размера.

Вход драфта — линейное отображение высокого ранга (половина ранга стоит 2–4 % τ) с одним-двумя доминирующими источниками. Разным токенам не нужны разные смеси, поэтому маршрутизировать нечего. Если МоЕ имеет смысл в EAGLE, то в FFN самого драфта, а это требует обучения драфта.

5 Выводы

1. Правило $(2, N/2, N - 3)$ — эвристика. Нижний слой можно убрать, средний выгоднее брать на глубине $\approx 0,7N$, верхний $(N - 3)$ выбран удачно.
2. Абляция статьи (тройка против последнего слоя) смешивает три эффекта: замену последнего слоя на $N - 3$, добавление слоёв и рост числа параметров. Наши данные показывают, что заметную часть разрыва даёт уже переход от последнего слоя к $N - 3$.
3. Нормализация каждого входа дешево устраняет перекося по масштабу ($+3N$ параметров, $+0,30 \tau$ на Qwen).
4. τ можно сжать до ранга $N/2$: на треть меньше параметров при потере 2–4 % τ .
5. МоЕ на уровне входа драфта не оправдан.

Ограничения. Две пары моделей, одна со сторонним драфтом. Полного обучения драфта не было: все сравнения слоёв сделаны при замороженном драфте. При подмене слоёв greedy-тексты расходятся с baseline на поздних токенах (численные эффекты bf16). Если считать $\Delta\tau$ только на общем начале текстов, оценки меняются не больше чем на 10 % величины эффекта.

Следующий шаг. Обучить только τ с многошаговой целью для наборов $(2, 16, 29)$, $(16, 22, 29)$, $(2, 22, 29)$, $(22, 29)$ на DSL-8B, около 1–2 часов на H200. Это проверит правило $0,7N$ на официальном драфте статьи по τ .

Код: `layer_study/ (layer_lab.py, h200/run.py)`; сырые результаты: `layer_study/results/h200/`.