

Какие слои большой модели нужны драфту EAGLE-3

Эксперимент с обучаемым выбором слоёв, драфт обучается целиком

Смена по воспроизведению EAGLE-3

7 октября 2026

Коротко

1. **Выводы прошлого исследования подтвердились.** Тогда драфт был заморожен, теперь он обучается целиком, а лучшие слои всё те же: около 70 % глубины сети и $N - 3$. Слой 2 не нужен.
2. **Лучший вариант — фиксированная тройка (14, 20, 25) с нормализацией.** Он даёт на 8 % больше принятых токенов, чем оригинальная тройка (2, 14, 25).
3. **Обучаемый выбор одних и тех же слоёв для всех токенов сам находит эту зону.** Без подсказок он пришёл к слоям (21, 24, 27) и почти догнал лучшую ручную тройку.
4. **Выбор слоёв отдельно для каждого токена (MoE) не помогает.** Версия с двумя слоями почти всегда берёт слой 20. Версия с тремя слоями застряла на последнем слое сети и стала хуже оригинала.
5. **Три слоя лучше двух.** Но в оригинале один из трёх слотов занят бесполезным слоем 2.

Рекомендация: брать слои ($N/2$, $0,7N$, $N - 3$) и нормализовать каждый вход. Это ничего не стоит на инференсе. Пословный роутер не нужен.

1 Что проверяли

Как устроен вход драфта. Драфт EAGLE-3 — маленькая модель из одного слоя. Она угадывает следующие токены, а большая модель (target) их проверяет. Чтобы угадывать лучше, драфт смотрит на внутренние состояния target. В оригинале берутся три слоя — 2, $N/2$ и $N - 3$ (у нашей модели $N = 28$, то есть слои 2, 14 и 25). Их склеивают в один вектор и сжимают одной матрицей до размера входа драфта. Набор слоёв зашит в код и одинаков для любой модели.

Что просили проверить. Обучать драфт целиком, а не только его вход. Вместо фиксированной тройки поставить роутер, который сам выбирает $k = 3$ или $k = 2$ слоя из всех 29 возможных. Дальше всё как в оригинале: склеить и сжать матрицей. Посмотреть, какие слои выбирает роутер, когда и от чего это зависит, и сравнить с прошлым исследованием, где драфт был заморожен.

Семь вариантов, обученных в одинаковых условиях:

- **Оригинал** — слои (2, 14, 25) как есть.
- **Оригинал + нормализация** — те же слои, но каждый приводится к одному масштабу. Иначе глубокие слои численно в десятки раз «громче» мелких и заглушают их.
- **(14, 20, 25) + нормализация** — лучшая тройка из прошлого исследования: слой 2 заменён на слой 20 ($\approx 0,7N$).

- **Статический роутер, top-3 и top-2** — у каждого слоя одна обучаемая оценка; берутся k лучших слоёв, *одни и те же для всех токенов*.
- **Пословный роутер, top-3 и top-2** — маленькая сеть смотрит на текущий токен и выбирает k слоёв *для каждого токена отдельно*. Это и есть МоЕ по слоям.

Чтобы роутер не застрял на первых случайно выбранных слоях, первые 30 % обучения к его оценкам добавлялся случайный шум. Роутеры почти не добавляют параметров: 59–119 тыс. при размере драфта около 120 млн.

Как обучали и оценивали. Модель — Qwen3-1.7B с публичным драфтом от AngelSlim. Обучались все семь вариантов параллельно, на одних и тех же 8000 ответах самой модели (запросы UltraChat и GSM8K), три эпохи. Это около 1,5 % объёма данных из статьи EAGLE-3. Качество метрили на 240 вопросах MT-bench, GSM8K и HumanEval, которых не было в обучении.

Метрика τ — сколько токенов в среднем получается за одну проверку большой моделью. $\tau = 3$ означает три токена за проход вместо одного. Чем больше τ , тем быстрее генерация.

2 Что получилось

Вариант	τ	Разница с оригиналом	95 %-интервал
оригинал (2, 14, 25)	3,05	—	
оригинал + нормализация	3,21	+0,16	[0,14; 0,18]
(14, 20, 25) + нормализация	3,29	+0,24 (+8 %)	[0,22; 0,26]
статический роутер, top-3	3,24	+0,19	[0,17; 0,21]
статический роутер, top-2	3,16	+0,11	[0,09; 0,12]
пословный роутер, top-3	3,00	−0,05	[−0,07; −0,04]
пословный роутер, top-2	3,14	+0,09	[0,07; 0,11]

Таблица 1: Итог после трёх эпох, 240 вопросов. Порядок вариантов одинаков на всех трёх бенчмарках по отдельности.




Рис. 1: Как росло качество по ходу обучения. Справа — насколько каждый вариант лучше оригинала. Серая полоса — период, когда роутер получал случайный шум.

Что видно:

- **Нормализация — самый дешёвый выигрыш:** +0,16 просто за выравнивание масштаба слоёв.

- Замена слоя 2 на слой 20 даёт ещё +0,08. Слой 2 занимает место, но почти ничего не даёт.
- Разрыв между вариантами со временем сокращается (рис. 1, справа). В начале обучения лучшая тройка опережала оригинал на 0,45, к концу — на 0,25. Обучаемый драфт частично сам подстраивается под неудачный вход. При полном объёме данных из статьи разница, скорее всего, будет меньше. При этом за всё обучение она ни разу не сменила знак: лучшие варианты всё время впереди.

3 Какие слои выбирает роутер и когда

3.1 Статический роутер: одни слои для всех токенов




Рис. 2: Слева — оценка каждого слоя по ходу обучения: красные слои роутер предпочитает, синие отвергает. Справа — какие слои выбраны в каждый момент. Пунктир — конец шума, оранжевая полоса — зона $0,7N$, синяя линия — $N - 3 = 25$.

Как менялся выбор:

- Сразу — в верхнюю треть сети. Уже к 0,1 эпохи роутер берёт слои 20–23. Это та же зона, что в прошлом исследовании дали и перебор слоёв по одному (лучший — 20), и обученная смесь всех слоёв.
- Затем выбор постепенно смещается глубже. Тор-2 к концу шума (0,9 эпохи) останавливается на слоях (25, 26) и больше их не меняет. Тор-3 продолжает менять слои и после шума и только к 1,9 эпохи приходит к (21, 24, 27). По смыслу это та же структура, что у лучшей ручной тройки: один слой около $0,7N$, один около $N - 3$ и ещё один рядом.
- Нижние слои 0–10 роутер отвергает с самого начала. Слой 2 из оригинала не выбрал ни один роутер ни разу.
- Почему top-2 хуже top-3. С двумя слотами роутер берёт два соседних глубоких слоя. Взять одновременно и зону $0,7N$, и верхний слой он не может.

3.2 Пословный роутер: свои слои для каждого токена




Рис. 3: Как часто пословный роутер выбирает каждый слой по ходу обучения. Светлее — чаще.

Тор-2 уже к 0,6 эпохи нашёл слой 20 и берёт его у 93 % токенов. Второй слой — обычно 18 или 19. По сути это почти фиксированный выбор, и он хуже статического роутера.

Тор-3 с самых первых шагов включил в набор последний слой сети (слой 28) и держит его у 99 % токенов. Остальные два места заняты в основном слоями 26 и 27. В прошлом исследовании последний слой оказался заметно хуже $N - 3$. Отказаться от него роутер не смог. Обучающий сигнал получают только уже выбранные слои, а оценка слоя 28 всё время оставалась высокой, так что остальные слои не могли его вытеснить. Итог — хуже оригинала.




Рис. 4: От чего зависит выбор пословного роутера в конце обучения: тип токена, уверенность большой модели, место в ответе, задача. Число I — насколько сильно выбор зависит от этого признака (0 — совсем не зависит).

От чего зависит выбор. Сильнее всего — от типа токена. Например, для пробелов и переносов строки top-2 чаще добавляет слой 25, для цифр берёт 19, а не 18. На трудных местах, где большая модель сама не уверена, роутер чаще берёт слои пониже: 18 у top-2, 15 и 24 у top-3. От задачи и от места в ответе выбор почти не зависит. В целом зависимость слабая: роутер выбирает «примерно одно и то же с небольшими вариациями».

Нужны ли драфту эти вариации? Мы проверили напрямую: всем токенам дали один и тот же, самый частый набор слоёв. τ упала ещё на 0,06 у обоих роутеров. Значит, драфт научился пользоваться пословным выбором. Но выигрыша он не даёт: оба пословных роутера всё равно хуже и статического роутера, и лучшей фиксированной тройки.

4 Сравнение с замороженным драфтом

Что меняли	Выигрыш у оригинала	
	драфт заморожен	драфт обучается
нормализация входов	+0,31	+0,16
тройка (14, 20, 25) + нормализация	+0,43	+0,24
выбор слоёв выучен, один для всех токенов	+0,38	+0,19
выбор слоёв для каждого токена	+0,41	от −0,05 до +0,09

Таблица 2: В прошлом исследовании обучался только вход драфта, а τ мерилась реальной генерацией. Поэтому сравниваются выигрыши, а не сами значения τ .

Что изменилось, когда драфт стал обучаться целиком:

- **Все выигрыши примерно вдвое меньше**, но порядок вариантов тот же. Обучаемый драфт частично сам исправляет неудачный вход.
- **Нужная зона слоёв та же:** около $0,7N$ и около $N - 3$. Слой 2 не нужен ни в одной постановке. Новое — выбор немного смещается вглубь, к слоям 24 и 27.
- **Пословный выбор стал рискованнее.** С замороженным драфтом роутер просто сходил к фиксированному набору (слои 20 и 25). С обучаемым драфтом он может закрепиться на неудачном слое и проиграть даже оригиналу.

5 Чего мы пока не знаем

- **Проверено на одной модели (Qwen3-1.7B)**, в одном запуске и на 1,5 % данных статьи. Нужна вторая модель: следующий шаг — DSL-8B с официальным драфтом авторов, около 6–8 часов на H200.
- **Скорость генерации не замерялась.** Но вход драфта у всех вариантов почти одинаков по стоимости, поэтому больше τ — быстрее генерация.
- **Пословный роутер, возможно, можно обучить лучше.** Сейчас обучающий сигнал получают только выбранные слои. Есть вариант, где сигнал получают все слои (как в Switch Transformer). Проверка займёт около часа и покажет, виноват ли в неудаче способ обучения.