

Какие слои большой модели нужны драфту EAGLE-3

Обучаемый выбор слоёв при обучаемом драфте: Qwen3-1.7B и DeepSeek-R1-Distill-Llama-8B

Смена по воспроизведению EAGLE-3

8 октября 2026

Коротко

1. **Обе модели выбирают одну и ту же зону слоёв:** около 70 % глубины сети и самый верх. Слой 2 из оригинала не выбрал ни один роутер ни разу.
2. **Выигрыш от другой тройки слоёв зависит от того, насколько хорош исходный драфт.** На Qwen3-1.7B со слабым публичным драфтом тройка ($N/2$, $0,7N$, $N - 3$) с нормализацией даёт +8 %. На DSL-8B с сильным официальным драфтом — ничья с оригиналом.
3. **Выбор слоёв для каждого токена (MoE) не помогает ни на одной модели.** Даже исправленный пословный роутер почти всегда выбирает одно и то же, а если всем токенам дать один набор, τ почти не меняется.
4. **Данных мало.** На DSL-8B наши варианты на 17 % хуже официального драфта на тех же вопросах. Выводы о сравнении вариантов корректны, но абсолютные значения занижены.

Рекомендация: оставить фиксированный набор из трёх слоёв, но заменить слой 2 на слой около $0,7N$. Пословный роутер не нужен. Окончательно сравнивать тройки стоит при полном объёме данных.

1 Что проверяли

Как устроен вход драфта. Драфт EAGLE-3 — маленькая модель из одного слоя. Она угадывает следующие токены, а большая модель (target) их проверяет. Чтобы угадывать лучше, драфт смотрит на три внутренних состояния target — из слоёв 2, $N/2$ и $N - 3$, где N — число слоёв. Их склеивают и сжимают одной матрицей. Набор слоёв зашит в код и одинаков для любой модели.

Что просили проверить. Обучать драфт целиком. Вместо фиксированной тройки поставить роутер, который сам выбирает 3 или 2 слоя из всех, дальше — как в оригинале. Посмотреть, какие слои он выбирает, когда и от чего это зависит, и сравнить с исследованием, где драфт был заморожен.

Семь вариантов, обученных в одинаковых условиях:

- **оригинал** — слои (2, $N/2$, $N - 3$) как есть;
- **оригинал + нормализация** — каждый слой приводится к одному масштабу (глубокие слои численно в десятки раз «громче»);
- ($N/2$, $0,7N$, $N - 3$) + **нормализация** — лучшая тройка из исследования с замороженным драфтом;

- **статический роутер, top-3 и top-2** — обучаемая оценка на каждый слой, k лучших слоёв *одни для всех токенов*;
- **пословный роутер, top-3 и top-2** — маленькая сеть выбирает k слоёв *для каждого токена*, это МоЕ по слоям.

Первые 30 % обучения к оценкам роутера добавлялся шум, чтобы он перепробовал разные слои.

Модели. **Qwen3-1.7B** ($N = 28$) с публичным драфтом AngelSlim и **DeepSeek-R1-Distill-Llama-8B** (DSL-8B, $N = 32$) с официальным драфтом авторов EAGLE-3. Драфт стартует с этих весов, матрица входа у всех вариантов учится с нуля. Данные — 8000 ответов самой модели (UltraChat и GSM8K), три эпохи, около 1,5 % объёма статьи. Оценка — 240 вопросов MT-bench, GSM8K и HumanEval, которых не было в обучении.

Метрика τ — сколько токенов в среднем получается за одну проверку большой моделью; больше — быстрее генерация. Здесь τ считается по одной цепочке глубиной 6; по дереву, как в статье, значения выше. Для сравнения вариантов между собой у всех одна и та же метрика.

2 Результаты

Вариант	Qwen3-1.7B		DSL-8B	
	τ	к оригиналу	τ	к оригиналу
оригинал	3,05	—	3,48	—
оригинал + нормализация	3,21	+0,16	3,46	−0,02
($N/2$, $0,7N$, $N - 3$) + нормализация	3,29	+0,24	3,48	+0,01 (незначимо)
статический роутер, top-3	3,24	+0,19	3,42	−0,06
статический роутер, top-2	3,16	+0,11	3,41	−0,07
пословный роутер, top-3	3,00*	−0,05	3,40	−0,07
пословный роутер, top-2	3,14*	+0,09	3,37	−0,11
официальный драфт с его входом	—		4,18	

Таблица 1: 240 вопросов. Все отличия от оригинала значимы (95 % bootstrap), кроме тройки с $0,7N$ на DSL-8B. * На Qwen у пословного роутера выбор застыл в начале обучения из-за слишком большого шага; на DSL-8B — исправленная версия.




Рис. 1: Качество по ходу обучения: сверху Qwen3-1.7B, снизу DSL-8B. Справа — разница с оригинальной тройкой. Серая полоса — период шума роутера.

Почему модели ведут себя по-разному. Обучаемый драфт стартует с весов, обученных под оригинальные слои, поэтому у оригинальной тройки есть фора. Драфт Qwen (AngelSlim) слабый, и фора почти ничего не значит: лучшая тройка сразу уходит вперёд, а к концу её отрыв сокращается с 0,45 до 0,25. Драфт DSL сильный, его авторы долго обучали именно под слои 2, 16, 29. Здесь лучшая тройка, наоборот, начинала с отставанием $-0,11$ и к концу догнала оригинал (рис. 1, справа). При полном объёме данных она, возможно, обогнала бы его, но это нужно проверить.

3 Какие слои выбирают роутеры




Рис. 2: Статический роутер: оценки слоёв (слева) и выбранные слои (справа). Сверху Qwen3-1.7B, снизу DSL-8B. Пунктир — конец шума, оранжевая полоса — $0,7N$, синяя линия — $N - 3$.

Статический роутер на обеих моделях сразу уходит в верхнюю треть сети и отвергает слои 0–10:

- **Qwen3-1.7B** ($0,7N \approx 20$, $N - 3 = 25$): top-3 к 1,9 эпохи приходит к (21, 24, 27), top-2 — к (25, 26).
- **DSL-8B** ($0,7N \approx 22$, $N - 3 = 29$): сразу после шума top-3 закрепляется на (22, 26, 30), top-2 — на (24, 29).

Структура одна и та же: слой около $0,7N$ и один-два слоя у самого верха.

Пословный роутер на Qwen3-1.7B застывал в первые десятки шагов: из-за большого шага обучения оценки слоёв обгоняли шум. Тор-3 закрепил последний слой 28 и стал хуже оригинала. Это исправлено (вход роутера нормирован, шаг меньше), и на DSL-8B считалась исправленная версия.

Исправленный пословный роутер на DSL-8B больше не застывает и не насыщается, но пользы не даёт:

- top-3 у 95 % токенов выбирает один и тот же набор (22, 30, 31) — фактически статический выбор;
- top-2 перебирает наборы разнообразно, но выбор почти не связан ни с типом токена, ни с уверенностью модели, ни с задачей;
- если всем токенам дать самый частый набор, τ падает всего на 0,005 (top-3) и 0,02 (top-2).

Выбирать слои отдельно для каждого токена не нужно: полезная информация для драфта лежит в одной и той же зоне слоёв для всех токенов.

4 Хватает ли данных и что драфт использует

DSL-8B, 240 вопросов	как есть	без признаков модели	без следующего токена
официальный драфт	4,18	1,02	1,06
наши варианты	3,37–3,48	1,00–1,01	1,15–1,17

Таблица 2: τ при обнулении частей входа драфта. «Без признаков модели» — вход из слоёв заменён нулями; «без следующего токена» — обнулён эмбединг уже известного следующего токена.

- **Данных мало.** Официальный драфт на тех же вопросах лучше наших вариантов на 17 %. Наша τ всё ещё росла каждую эпоху (3,15 $\rightarrow$ 3,42 $\rightarrow$ 3,52), так что больше данных и шагов дали бы больше. Сравнение вариантов между собой корректно (условия одинаковые), но абсолютные цифры занижены.
- **Обе части входа необходимы.** Без признаков модели τ падает до 1 — драфт перестаёт угадывать. Без эмбединга следующего токена — тоже почти до 1. Ни одна часть не заменяет другую.

5 Сравнение с замороженным драфтом

Что меняли	Выигрыш у оригинала		
	заморожен (Qwen)	обучается (Qwen)	обучается (DSL)
нормализация входов	+0,31	+0,16	−0,02
тройка ($N/2$, $0,7N$, $N-3$) + нормализация	+0,43	+0,24	+0,01
выученный выбор, один для всех токенов	+0,38	+0,19	−0,06
выбор для каждого токена	+0,41	от −0,05 до +0,09	−0,07 ... − 0,11

Таблица 3: В исследовании с замороженным драфтом обучался только вход, τ мерилась реальной генерацией; сравниваются выигрыши, а не сами значения.

Чем больше драфт обучается сам (и чем сильнее он был изначально), тем меньше выигрыш от выбора слоёв: обучаемый драфт частично подстраивается под любой вход. Зона полезных слоёв при этом одна и та же во всех постановках.

6 Что дальше

- **Обучить лучшие варианты на полном объёме данных** (или хотя бы в несколько раз больше), чтобы понять, сохраняется ли выигрыш тройки с $0,7N$ и догоняет ли она официальный драфт.
- **Убрать фору оригинальных слоёв:** обучать драфт с нуля для каждого варианта, а не со старта под слои $2, N/2, N - 3$.
- **Замерить скорость** лучших вариантов в настоящей генерации деревом.