


Метод 5: что именно обучается и как устроены варианты

■ обучается ■ заморожено, не меняется ■ данные (векторы)

1. Общий конвейер




Шаг обучения. Берём текст, который сгенерировала сама target-модель. Прогоняем его через target и сохраняем векторы всех слоёв. F собирает из них g. Драфт по g и эмбедингу следующего токена предсказывает токен после него. Сравниваем с тем, что предсказала target, и обновляем только F. Так 1000 шагов на 8000 текстах, все варианты F на одних и тех же данных.

Проверка. Обученный F ставится в EAGLE вместо f_c. Запускаем обычную спекулятивную генерацию на 160 вопросах (MT-bench + GSM8K) и меряем τ — сколько токенов принимается за цикл.


2. Какие бывают F

а) Как в upstream: три слоя → склейка → Linear



Слои подаются как есть. Норма $h_{\{N-3\}}$ в десятки раз больше, чем у h_2 , поэтому Linear в основном «слышит» верхний слой. Qwen: **т 3,37**.


б) То же + нормализация каждого слоя



каждый слой приводится к одному масштабу


Все слои становятся «одинаково громкими». Qwen: (2,14,25) **т 3,68**; с заменой 14 на 20, то есть (14,20,25): **т 3,80**. Так же устроены «пара» и «один слой», просто входов 2 или 1.

в) Смесь всех слоёв: модель сама выбирает слои




Каждый слот Σ_s — взвешенная сумма **всех** слоёв (после нормализации). Веса — обучаемый softmax, **одни и те же для всех токенов**. Жирные линии показывают, куда веса сошлись на Qwen: слои 18–22 и 25. τ **3,75**.

г) MoE №1 — роутер по слоям: «эксперты» = слои target



Отличие от (в) только в том, что веса слоёв зависят от токена. Идея: коду нужны одни слои, математике другие. Результат: роутер почти для всех токенов выбирает одно и то же (слои 18–20 и 25). Qwen: τ **3,78**, +0,03 к (в).

д) MoE №2 — эксперты внутри Linear: один общий блок + 4 эксперта, на токен работает один



Один Linear $3N \rightarrow N$ заменён на «общая часть + специалист». Роутер для каждого токена выбирает одного из 4 экспертов. Результат: без штрафа 85% токенов уходит к одному эксперту (у DSL 99,8%). Со штрафом нагрузка ровная (22–26%), но эксперты не специализируются, и качество не лучше обычного Linear того же размера. Qwen: **τ 3,72** и **3,70** со штрафом против **3,74** у обычного low-rank.

Итог в одной строке

Метод 5 меняет только синий/оранжевый блок «модуль входа» и смотрит, как изменится τ . Помогли нормализация (б) и выбор слоя $\approx 0,7N$ вместо $N/2$. Оба варианта MoE (г, д) не дали выигрыша, потому что всем токенам нужны одни и те же слои.