

# Почему ускорение EAGLE-3 зависит от машины

Профиль кода авторов на H200 и A100: LLaMA-3.1-8B-Instruct, официальный драфт

Смена по воспроизведению EAGLE-3

9 октября 2026

## Коротко

1.  **$\tau$  совпадает со статьёй на обеих машинах** (6,25 на H200, 6,27 на A100, 6,23 в статье), а ускорение разное: H200 3,38×, A100 4,02×, статья 4,44× ( $T = 0$ ). Вся разница — в стоимости цикла EAGLE в шагах обычной генерации: H200 1,85, A100 1,56, статья  $\approx 1,40$ .
2. **По работе GPU цикл стоит  $\approx 1,6$  обычного шага на обеих картах**, по числу запусков ядер —  $\approx 1,5$ . Это свойство кода, а не GPU.
3. **Реальная стоимость цикла зависит от того, во что упирается шаг**. H200 с быстрым CPU упирается в работу GPU: цикл  $\approx 1,67$ . A100 в виртуалке DataSphere упирается в запуск ядер (CPU тратит  $\approx 22$  мкс на запуск против  $\approx 7$  мкс на H200): цикл 1,47, ускорение 4,0–4,3×.
4. **Ускорение — отношение к обычной генерации на той же машине**. Чем медленнее обычная генерация, тем оно больше. В абсолютной скорости H200 быстрее A100 в 2,8 раза.
5. **Прошлая гипотеза не подтвердилась**. Мы предполагали, что мелкие ядра драфта не ускоряются на быстрой памяти и на A100 цикл будет  $\approx 1,40$ . На деле на A100 все ядра, включая драфт, медленнее примерно в 2 раза.

## Как мерили

Код авторов (SafeAIlab/EAGLE, коммит cb7e084) без изменений, дерево как в статье EAGLE-3 (60 токенов, глубина 8, top-k 10),  $T=0$ , fp16; MT-bench, первые ходы 5 вопросов. Скрипт `profile_eagle.py` оборачивает фазы цикла снаружи: время каждой фазы — между синхронизациями CUDA, а `torch.profiler` даёт длительность каждого CUDA-ядра. **GPU-работа** — сумма длительностей ядер, запущенных из фазы; на неё профилировщик почти не влияет (в отличие от общего времени, которое он растягивает, нагружая CPU).

Машины: H200 NVL на сервере с AMD EPYC 9555 (Zen 5); A100-SXM4-80GB в виртуальной машине Yandex DataSphere (28 vCPU AMD EPYC, модель скрыта облаком). Torch 2.5.1 на обеих.


Ускорение =  $\tau$  / (стоимость цикла в шагах обычной генерации). При одинаковом  $\tau$  ускорение определяется только тем, во сколько обычных шагов обходится цикл.

## Из чего состоит цикл: H200 и A100

|                                              | H200           |             | A100           |             |
|----------------------------------------------|----------------|-------------|----------------|-------------|
|                                              | GPU-работа, мс | Ядер        | GPU-работа, мс | Ядер        |
| Шаг обычной генерации                        | 8,2            | 1 766       | 16,4           | 1 855       |
| проверка дерева большой моделью (60 токенов) | 9,7            | 1 758       | 18,7           | 1 853       |
| драфт (8 шагов дерева)                       | 3,6            | 885         | 7,4            | 900         |
| выбор ветки и обновление кэша                | 0,1            | 20          | 0,2            | 20          |
| <b>Цикл / обычный шаг</b>                    | <b>1,64</b>    | <b>1,51</b> | <b>1,61</b>    | <b>1,49</b> |


| Реальное время (без профилировщика)          | H200              | A100               |
|----------------------------------------------|-------------------|--------------------|
| Обычный шаг                                  | 12,7 мс           | 40,6 мс            |
| из них GPU считает                           | 8,2 мс (65 %)     | 16,4 мс (40 %)     |
| нижняя граница: прочитать 16 ГБ весов        | 3,4 мс (4,8 ТБ/с) | 7,9 мс (2,04 ТБ/с) |
| Время на один запуск ядра (шаг / число ядер) | ≈7 мкс            | ≈22 мкс            |
| Цикл EAGLE                                   | 21,3 мс           | 59,8 мс            |
| <b>Цикл / обычный шаг</b>                    | <b>1,67</b>       | <b>1,47</b>        |
| Ускорение на этих 5 вопросах                 | 3,75×             | 4,29×              |
| Ток/с: обычная генерация → EAGLE             | ≈79 → ≈294        | 24,6 → 105,6       |

- **GPU-работа на A100 вдвое больше на всех фазах**, включая мелкие ядра драфта (7,4 против 3,6 мс). Это примерно разница в пропускной способности памяти. Поэтому по работе GPU цикл стоит одинаково, ≈1,6 шага.
- **Проверка дерева из 60 токенов запускает столько же ядер, сколько обычный шаг** (1 853 против 1 855 на A100), а драфт добавляет ≈900. По запускам цикл стоит ≈1,5 шага.
- **На H200 реальное время повторяет GPU-работу** (1,67 ≈ 1,64): GPU занят 65 % шага, CPU успевает запускать ядра.
- **На A100 реальное время повторяет число запусков** (1,47 ≈ 1,49): GPU занят лишь 40 % шага, остальное ждёт запуска следующего ядра. Медленный запуск сильнее бьёт по обычной генерации (1 855 ядер на 1 токен), чем по EAGLE (≈2 770 ядер на 6,3 токена).



**Рис. 1:** Стоимость цикла EAGLE в обычных шагах: по работе GPU, по числу запусков ядер и по реальному времени. На H200 реальное время следует за работой GPU, на A100 — за числом запусков.

## Таймлайны




**Рис. 2:** H200. Два цикла EAGLE (проверка дерева — оранжевым, драфт — синим), увеличенные окна по 0,5 мс внутри драфта и внутри проверки, и три шага обычной генерации. Верхняя дорожка — фаза на CPU, средняя — запуски ядер, нижняя — ядра на GPU. Белые промежутки на дорожке GPU — простой. Под профилировщиком CPU медленнее, поэтому простоя больше, чем без него.

## Что стало с прошлой гипотезой


До замера на A100 мы объясняли разрыв со статьёй так: мелкие ядра драфта не ускоряются на быстром GPU, а обычный шаг на H200 очень быстрый из-за памяти 4,8 ТБ/с. Подставив память A100, модель предсказывала цикл  $\approx 1,40$  и ускорение  $\approx 4,5\times$ . **Замер это не подтвердил:** на A100 ядра драфта медленнее так же, как и все остальные, и цикл по работе GPU остался  $\approx 1,6$ . Ускорение на A100 выросло по другой причине — медленный запуск ядер в виртуальной машине.

## Что из этого следует

- **Воспроизведение корректно:** драфт, дерево и протокол дают те статьи на обеих машинах.
- **Ускорение EAGLE в исследовательском коде — не константа метода.** Оно тем выше, чем медленнее обычная генерация на машине:  $3,38\times$  на H200 с быстрым CPU,  $4,02\times$  на A100 в вир-



**Рис. 3:** A100, то же самое. Внутри драфта и проверки GPU занят 12–14 % окна: ядра по несколько микро-секунд, между ними десятки микросекунд ожидания запуска.



**Рис. 4:** H200. Слева: 91 % ядер короче 10 мкс (медиана 2–3 мкс) и в обычной генерации, и в EAGLE. Справа: на что тратится время GPU в EAGLE — GEMM-ядра и мелкие поэлементные операции. На A100 картина та же (медиана 4 мкс, 87–88 % короче 10 мкс).

туалке, 4,44× в статье. Машина авторов в статье не указана; остаток  $\approx 10\%$  (цикл 1,40 против наших 1,47–1,56) могут давать другое железо, версии библиотек или иной замер — различить это мы не можем.

- **Сравнивать надо и ускорение, и абсолютные ток/с.** В SGLang (задача 3b) ускорение ещё ниже (3,06×), зато абсолютная скорость в  $\approx 1,9$  раза выше, чем у кода авторов: база там быстрее.
- **Чтобы цикл стал дешевле, нужно сократить число мелких ядер драфта и проверки** (слияние операций, CUDA graphs) — этим и занимается SGLang.

Код и сырые числа: [reproduction/](#) (code/inference\_speed/profile\_eagle.py, plot\_profile.py, results/profile\_3a.md, results/a100.md).